

Pré-Treino, Pós-Treino, Destilação, RAG e Guardrails de Modelos de Linguagem para o Domínio Público Piauiense: Relatório das Questões 01 a 06

Allycia, Heverton, Izaías, Oscar¹

¹Departamento de Computação, Centro de Ciências da Natureza

Universidade Federal do Piauí (UFPI), Teresina, PI

Disciplina: Tópicos em Inteligência Artificial.

Professor: Raimundo Santos Moura.

Período 2026.1

Resumo. *Este relatório reúne as seis questões do trabalho final sobre adaptação de modelos de linguagem ao domínio público piauiense. Nas três primeiras, todas conduzidas sobre o Qwen2.5-0.5B em uma única sessão de GPU T4 no Kaggle: o pré-treinamento continuado sobre 71.431 documentos do Diário Oficial dos Municípios do Piauí (DOMPI-2025) reduziu a perplexidade de 21,78 para 2,09 e a acurácia de previsão de tokens de 42,25% para 82,03% (Questão 01); um ajuste fino supervisionado completo com 1.977 pares de instrução gerados a partir do dataset docentesDC reduziu a perplexidade sobre os tokens de resposta de 14,57 para 7,49 (Questão 02); e o mesmo experimento com QLoRA atualizou apenas 0,44% dos parâmetros atingindo perplexidade 6,40 com 5,5 vezes menos memória (Questão 03), com um experimento adicional no Qwen2.5-1.5B quantizado obtendo o melhor pós-treino (perplexidade 4,75). As três últimas questões estendem o estudo: a destilação por Chain-of-Thought de um professor Qwen2.5-3B para um aluno Qwen2.5-1.5B reduziu a perplexidade do aluno em 22,9%, mas revelou divergência entre métricas automáticas e semânticas (Questão 04); uma aplicação de RAG sobre o docentesDC, avaliada com o framework Ragas em 30 perguntas, mostrou redução de alucinações apesar de pontuações limitadas por lacunas do corpus (Questão 05); e uma camada de guardrails sobre o modelo da Questão 02 bloqueou 100% das ameaças de um benchmark de 30 perguntas com apenas 5% de falsos positivos (Questão 06).*

1. Introdução

Modelos de linguagem de grande porte (*Large Language Models*, LLMs) são pré-treinados sobre vastos corpora de texto de propósito geral. Embora isso lhes confira fluência ampla, o conhecimento adquirido tende a ser raso em domínios especializados e em variedades regionais da língua, pouco representados nos dados de origem. Adaptar esses modelos a um domínio específico, com custo computacional acessível, é um problema central tanto na pesquisa quanto na aplicação prática de Processamento de Linguagem Natural [[Gururangan et al. 2020](#)].

Este relatório documenta as seis questões do trabalho final da disciplina de Tópicos em Inteligência Artificial, todas voltadas à adaptação de modelos de linguagem da família

Qwen2.5 [Qwen Team 2024] ao domínio público piauiense. As três primeiras questões formam um núcleo homogêneo, conduzido sobre o Qwen2.5-0.5B em uma única sessão de GPU, cada uma correspondendo a uma técnica distinta de treinamento:

- **Questão 01, Pré-Treino Continuado.** Adaptação não supervisionada do modelo ao corpus DOMPI-2025 (Diário Oficial dos Municípios do Piauí), avaliando a qualidade da modelagem de linguagem antes e depois do treino, complementada por um *benchmark* de 25 perguntas respondido pelos dois modelos.
- **Questão 02, Pós-Treino com SFT.** Ajuste fino supervisionado (*Supervised Fine-Tuning*) sobre 1.977 pares de instrução e resposta gerados programaticamente a partir do dataset docentesDC, atualizando todos os parâmetros do modelo.
- **Questão 03, Pós-Treino com QLoRA.** Repetição do experimento anterior por meio de adaptação de baixo posto sobre o modelo quantizado em 4 bits, atualizando 0,44% dos parâmetros, com comparação direta de custo e qualidade frente ao ajuste fino completo. Um experimento adicional aplica a mesma técnica ao Qwen2.5-1.5B, atendendo ao item opcional de considerar mais de um modelo.

As três questões seguintes ampliam o escopo para além do treinamento de um único modelo, cobrindo compressão, recuperação de informação e segurança:

- **Questão 04, Destilação de Conhecimento.** Transferência de conhecimento de um modelo professor Qwen2.5-3B para um aluno Qwen2.5-1.5B por meio de destilação por *Chain-of-Thought* sobre um dataset sintético, com avaliação por um *benchmark* de 100 perguntas para verificar se houve efetiva transferência.
- **Questão 05, RAG.** Uma aplicação de *Retrieval-Augmented Generation* do tipo *Standard* sobre o dataset docentesDC, avaliada com um *benchmark* de 30 perguntas, medindo a contribuição da recuperação de contexto na redução de alucinações.
- **Questão 06, Guardrails.** Adição de camadas de controle (*guardrails*) sobre o modelo pós-treinado na Questão 02, avaliadas com um *benchmark* de 30 perguntas que quantifica o grau de proteção adicionado ao modelo.

As técnicas são avaliadas pelas mesmas métricas quantitativas de modelagem de linguagem (perplexidade, entropia cruzada e acurácia de previsão de tokens [Jelinek et al. 1977]), sempre antes e depois do treino, sobre conjuntos de avaliação reservados. A hipótese geral é que o treinamento, em todas as suas formas, reduz a incerteza do modelo sobre o texto do domínio e melhora sua capacidade de previsão.

1.1. Escopo e execução

Os experimentos das Questões 01 a 03 foram executados de ponta a ponta em uma única sessão de GPU NVIDIA T4 na plataforma Kaggle, por meio de um *notebook* unificado que encadeia as três questões e salva todas as métricas, gerações e figuras de forma estruturada. A sessão completa, incluindo o experimento adicional com o modelo de 1,5 bilhão de parâmetros, durou 5 horas e 34 minutos. As Questões 04 a 06, por envolverem modelos, ferramentas e ambientes distintos, foram desenvolvidas separadamente pelos integrantes do grupo, cada uma com seu próprio *notebook* e conjunto de artefatos (detalhados na Seção 3). Todos os números reportados neste documento provêm dos artefatos dessas execuções; nenhuma métrica é estimada.

2. Fundamentação Teórica

2.1. Modelos de linguagem e o objetivo de pré-treino

Um modelo de linguagem autorregressivo, baseado na arquitetura *Transformer* [Vaswani et al. 2017], estima a probabilidade do próximo token x_t dado o contexto anterior, $P(x_t | x_{<t})$. O treinamento minimiza a entropia cruzada média entre a distribuição prevista e o token observado:

$$\mathcal{L} = -\frac{1}{N} \sum_{t=1}^N \log P(x_t | x_{<t}), \quad (1)$$

onde N é o número de tokens. O Qwen2.5-0.5B adotado neste trabalho possui 494 milhões de parâmetros, 24 camadas, dimensão oculta de 896 e vocabulário de 151.936 tokens [Qwen Team 2024].

2.2. Pré-treino continuado (*continued pretraining*)

O pré-treino continuado consiste em prosseguir o treino não supervisionado de um modelo já pré-treinado sobre um corpus de um domínio-alvo, usando o mesmo objetivo da Equação 1. A técnica adapta o modelo ao vocabulário, ao estilo e às regularidades estatísticas do domínio sem necessidade de rótulos, e é reconhecidamente eficaz para domínios especializados [Gururangan et al. 2020]. É a abordagem da Questão 01.

2.3. Pós-treino: ajuste fino supervisionado (SFT)

O *Supervised Fine-Tuning* (SFT) treina o modelo sobre pares de instrução e resposta, ensinando-o a seguir comandos e a responder no formato desejado [Ouyang et al. 2022]. Os exemplos seguem tipicamente um molde de prompt como o do *Stanford Alpaca* [Taori et al. 2023], com campos de instrução, entrada opcional e resposta. No SFT clássico (Questão 02), todos os parâmetros do modelo são atualizados, o que oferece máxima capacidade de adaptação ao custo de elevada demanda de memória e tempo.

2.4. Adaptação eficiente: LoRA e QLoRA

A *Low-Rank Adaptation* (LoRA) [Hu et al. 2022] congela os pesos originais W_0 e aprende apenas um par de matrizes de baixo posto A e B , de modo que a atualização efetiva seja $W_0 + BA$, com $\text{posto}(BA) = r \ll d$. Como apenas A e B são treinados, o número de parâmetros atualizados cai em ordens de grandeza, reduzindo memória e tempo sem alterar a arquitetura na inferência.

O QLoRA [Dettmers et al. 2023] estende a ideia carregando o modelo base *quantizado* em 4 bits (formato NF4) e aplicando os adaptadores LoRA sobre essa representação comprimida. Isso permite ajustar modelos em GPUs modestas. Ambas as técnicas são disponibilizadas pela biblioteca PEFT [Mangrulkar et al. 2022] e correspondem à Questão 03.

2.5. Máscara de perda e avaliação por tokens de resposta

No SFT, cada exemplo concatena o prompt (instrução e entrada) com a resposta esperada. Se a perda da Equação 1 for calculada sobre a sequência inteira, o modelo gasta capacidade

aprendendo a reproduzir o próprio enunciado, que se repete entre os exemplos. Por isso, adota-se uma *máscara de perda*: os tokens do prompt recebem rótulo ignorado e apenas os tokens da resposta contribuem para o gradiente. Pela mesma razão, as métricas das Questões 02 e 03 são calculadas somente sobre os tokens de resposta, antes e depois do treino, medindo a capacidade de *responder* e não a de memorizar o molde da instrução. Uma consequência importante é que essas métricas não são comparáveis, em valor absoluto, às da Questão 01, que avaliam a sequência completa.

2.6. Métricas de avaliação

As três questões usam o mesmo conjunto de métricas, calculadas sobre um conjunto de avaliação reservado (*held-out*):

- **Entropia cruzada:** a perda média da Equação 1; quanto menor, melhor o ajuste do modelo ao texto.
- **Perplexidade:** o exponencial da entropia cruzada, $PPL = e^{\mathcal{L}}$ [Jelinek et al. 1977]. Interpreta-se como o número médio de opções entre as quais o modelo hesita por token; uma perplexidade próxima de 1 indica previsão quase determinística.
- **Acurácia de previsão de tokens:** a fração de tokens em que o token de maior probabilidade (*argmax*) coincide com o token real.

2.7. Destilação de conhecimento

A destilação de conhecimento (*knowledge distillation*) [Hinton et al. 2015] transfere o conhecimento de um modelo maior (*teacher*) para um modelo menor (*student*), de modo que o aluno aproxime o comportamento do professor com menos parâmetros e menor custo de inferência. A formulação clássica minimiza a divergência entre as distribuições de *logits* dos dois modelos. Uma variante mais recente, adotada na Questão 04, é a *destilação por Chain-of-Thought (CoT)*: o professor gera não apenas a resposta final, mas também o raciocínio passo a passo que a justifica, e o aluno é ajustado por SFT sobre esses pares raciocínio-resposta. Essa abordagem se aproxima do *instruction tuning* com dados sintéticos gerados por um modelo mais capaz, dispensando o acesso aos *logits* internos do professor.

2.8. Geração aumentada por recuperação (RAG)

O *Retrieval-Augmented Generation* (RAG) [Lewis et al. 2020] acopla a um LLM uma etapa de recuperação: a pergunta do usuário é usada para buscar, em uma base de documentos, os trechos mais relevantes, que são então inseridos no *prompt* como contexto. Assim o modelo responde ancorado em fontes externas, reduzindo alucinações sem necessidade de re-treino. A recuperação típica indexa *chunks* de texto por *embeddings* vetoriais em um banco vetorial e recupera os vizinhos mais próximos da consulta. A qualidade de um pipeline de RAG pode ser avaliada, sem gabarito humano exaustivo, pelo *framework* Ragas [Es et al. 2024], que emprega um LLM como juiz para estimar métricas como **fidelidade** (*faithfulness*: se a resposta se apoia apenas no contexto recuperado), **relevância da resposta** (*answer relevancy*) e **precisão do contexto** (*context precision*: se os trechos úteis foram bem ranqueados). É a técnica da Questão 05.

2.9. Guardrails e o dilema *helpfulness* contra *harmlessness*

Guardrails são camadas de controle intercaladas ao fluxo de um LLM que podem bloquear, reescrever, classificar, mascarar dados sensíveis, redirecionar o diálogo ou exigir confirmação antes de ações perigosas. Elas endereçam diretamente o dilema entre ser útil (*helpfulness*) e ser seguro (*harmlessness*): uma resposta maximamente prestativa pode ser perigosa, e uma excessivamente restritiva torna-se inútil. Arquiteturas como o *NeMo Guardrails* [Rebedea et al. 2023] organizam essas camadas em trilhos (*rails*) de entrada, de tópico e de saída. A eficácia de uma camada de proteção é medida sobre um *benchmark* que mistura solicitações legítimas e maliciosas, quantificando a **taxa de detecção de ameaças** (proporção de solicitações perigosas corretamente bloqueadas) e a **taxa de falsos positivos** (proporção de solicitações legítimas bloqueadas indevidamente). É o objeto da Questão 06.

3. Metodologia Geral

3.1. Conjuntos de dados

DOMPI-2025 (Questão 01). O corpus DOMPI-2025 [Portela 2025] reúne publicações do Diário Oficial dos Municípios do Piauí (DOM-PI) referentes a 2025, distribuídas em 12 territórios de desenvolvimento do estado. O texto foi extraído dos PDFs originais com PaddleOCR, Docling e PyMuPDF, totalizando 77.337 documentos brutos. Trata-se de linguagem jurídico-administrativa: portarias, decretos, extratos de contrato, editais de licitação e relatórios fiscais.

docentesDC (Questões 02 e 03). O dataset docentesDC [Minari 2025] contém materiais acadêmicos (slides, notas de aula, fragmentos de código e artigos) de 19 professores do Departamento de Computação da UFPI, em 13.762 registros com os campos `text` e `nome_professor`. O conteúdo é heterogêneo e ruidoso: além de texto em português extraído de slides, há artigos científicos em inglês fatiados em blocos e código-fonte em linguagem C. É a base do pipeline de geração de pares descrito na Seção 5.

3.2. Modelo e ambiente computacional

Todos os experimentos partem do mesmo modelo base, Qwen2.5-0.5B, carregado via biblioteca *Transformers* [Wolf et al. 2020]. A execução ocorreu em uma única sessão da plataforma Kaggle, em um *notebook* unificado que encadeia as três questões, com uma única GPU NVIDIA T4 (16 GB) visível. A escolha de uma única T4 (em vez das duas disponíveis) foi deliberada: com duas GPUs, o *Trainer* ativaria *DataParallel* e concentraria os *logits* do vocabulário de 151 mil tokens em uma só placa, estourando a memória.

Por exigência do *GradScaler* usado no treino em precisão mista (`fp16` com *autocast*), os pesos mestres dos treinos completos foram mantidos em `fp32`; a T4 não possui suporte de hardware a `bfloat16`. Empregou-se *gradient checkpointing* em todos os treinos para reduzir o consumo de memória, e o melhor *checkpoint* de cada treino foi selecionado pela menor perda de validação (`load_best_model_at_end`).

3.3. Protocolo de avaliação

Para cada experimento, o modelo é avaliado *antes* e *depois* do treino sobre o mesmo conjunto reservado, usando as métricas da Seção 2.6. Na Questão 01 as métricas cobrem a sequência completa (modelagem de linguagem pura); nas Questões 02 e 03, apenas os tokens de resposta, conforme a Seção 2.5. A avaliação quantitativa é complementada por comparações qualitativas com geração determinística (*greedy*), garantindo que as respostas registradas antes e depois sejam reproduzíveis. Sementes aleatórias fixas controlam embaralhamentos e divisões de dados. A Tabela 1 resume os quatro experimentos executados.

Tabela 1. Visão geral dos experimentos executados na sessão única de T4.

Experimento	Técnica	Dataset	Params. treinados	Tempo	VRAM
Questão 01	Pré-treino continuado	DOMPI-2025	494M (100%)	4h23	10,60 GB
Questão 02	SFT completo	docentesDC	494M (100%)	11 min	9,77 GB
Questão 03	QLoRA (NF4)	docentesDC	2,16M (0,44%)	18 min	1,77 GB
Adicional	QLoRA no 1.5B	docentesDC	4,36M (0,28%)	26 min	2,75 GB

3.4. Ambientes e recursos das Questões 04 a 06

As Questões 04 a 06 ampliam o estudo para técnicas que não se resumem ao treino de um único modelo e, por isso, foram desenvolvidas em ambientes próprios, com modelos e ferramentas distintos dos das três primeiras. A Questão 04 usa dois modelos da família Qwen2.5 na variante -Instruct (professor de 3 bilhões e aluno de 1,5 bilhão de parâmetros) e o mesmo corpus DOMPI-2025 da Questão 01, agora como fonte de um dataset sintético de destilação. A Questão 05 não treina modelo algum: monta um pipeline de RAG sobre o docentesDC com serviços da OpenAI para geração e *embeddings*. A Questão 06 reaproveita o próprio modelo pós-treinado na Questão 02, adicionando-lhe camadas de *guardrails* baseadas em regras. A Tabela 2 resume esses ambientes.

Tabela 2. Modelos, dados, ferramentas e ambientes das Questões 04 a 06.

Questão	Modelo(s)	Dataset	Principais ferramentas	Ambiente
Q4 Destilação	Qwen2.5-3B → 1.5B-Instruct	DOMPI-2025 (sintético, 100 trechos)	Transformers, PEFT/LoRA, SFTTrainer, LLM-as-Judge	GPU RTX 4050 (6 GB)
Q5 RAG	gpt-4o-mini + text-embedding-3-small	docentesDC	LangChain, ChromaDB, Ragas	API OpenAI (local)
Q6 Guardrails	Qwen2.5-0.5B (SFT da Q2)	docentesDC	Transformers + trilhos de regras (<i>regex</i>)	CPU (local)

4. Questão 01: Pré-Treino Continuado

4.1. Objetivo e configuração

A Questão 01 realiza o pré-treino continuado do Qwen2.5-0.5B sobre o corpus DOMPI-2025, avaliando se o modelo melhora sua capacidade de modelar a linguagem jurídico-administrativa do Piauí. Dos 77.337 documentos brutos, 72.431 passaram pelo filtro de

tamanho (entre 200 e 50.000 caracteres); destes, 71.431 foram usados no treino e 1.000 reservados para avaliação *held-out*. A Tabela 3 apresenta os hiperparâmetros efetivos.

Tabela 3. Hiperparâmetros do pré-treino continuado (Questão 01).

Item	Valor
Documentos de treino / avaliação	71.431 / 1.000 (<i>held-out</i>)
Épocas	2
Tamanho de lote efetivo	32
Taxa de aprendizado	5×10^{-5} com decaimento cosseno
Comprimento máximo de sequência	256 tokens
Precisão	fp32 + <i>autocast</i> fp16, <i>gradient checkpointing</i>
Passos de treino / tempo	4.466 passos / 15.810 s ($\approx$ 4h23 em 1 GPU T4)
Pico de memória de GPU	10,60 GB
<i>Loss</i> final de treino	0,8943
Melhor <i>checkpoint</i>	passo 4.466 (fim da época 2)

4.2. Resultados quantitativos

A Tabela 4 e a Figura 1 apresentam as métricas sobre os 1.000 documentos reservados, antes e depois do treino. A perplexidade caiu de 21,78 para 2,09 (redução de 90,4%), a entropia cruzada caiu 76% e a acurácia de previsão de tokens quase dobrou, de 42,25% para 82,03%.

Tabela 4. Métricas da Questão 01 sobre o conjunto *held-out* (1.000 documentos).

Métrica	Antes	Depois	Δ	Variação
Entropia Cruzada	3,0812	0,7381	-2,3431	-76%
Perplexidade	21,78	2,09	-19,69	-90,4%
Acurácia de Tokens	42,25%	82,03%	+39,78 p.p.	+94%

4.3. Dinâmica do treino e ausência de *overfitting*

A Figura 2 mostra a evolução da perda. A perda de treino cai de 2,05 para 0,64 de forma monotônica, e a perda de validação diminui entre as épocas (0,8423 ao fim da época 1; 0,7356 ao fim da época 2). O melhor *checkpoint* selecionado pelo Trainer foi, portanto, o do último passo: não houve sinal de *overfitting*, pois um modelo que tivesse decorado o conjunto de treino teria visto a perda de validação subir na segunda época. A avaliação final foi feita nesse ponto ótimo.

4.4. Análise qualitativa

Submetendo os mesmos prompts ao modelo base e ao modelo treinado, o contraste é nítido: o modelo treinado produz texto administrativo autêntico do Piauí, enquanto o base divaga em conteúdo genérico, muitas vezes de outros estados.




Figura 1. Métricas de modelagem de linguagem antes e depois do pré-treino continuado. A perplexidade cai de cerca de 22 para cerca de 2, indicando que o modelo passou a prever o próximo token com pouquíssima hesitação no domínio.




Figura 2. Curvas de perda do pré-treino continuado. A perda de validação continua caindo até o fim da segunda época.

Prompt: “O Prefeito Municipal, no uso de suas atribuições legais,”

Base: “... promoveu a realização de um sorteio para o prêmio do Imposto sobre as receitas brutas (IRBR) 2018...” (texto genérico, fora de domínio).

Treinado: “...e com fulcro na Lei n. 14.133/2021 e demais normas pertinentes, RESOLVE, após exame criterioso de documentação e acatando a opinião da Comissão Permanente de Licitação...”

Prompt: “EXTRATO DE CONTRATO. Contratante: Prefeitura Municipal de”

Base: “São Pedro, do Distrito Federal, e do Município de Ipiranga... O Tribunal Regional Federal da 4ª Região...” (alucinação fora de domínio).

Treinado: “São João do Arraial-PI, CNPJ n. 01.612.609/0001-84. Contratado: A. C. GOMES COMÉRCIO DE MATERIAIS ESPORTIVOS E CONSTRUÇÃO LTDA...”

O modelo treinado acerta a lei vigente de licitações (14.133/2021), cita municípios reais do Piauí (São João do Arraial, Caldeirão Grande do Piauí) e reproduz a estrutura de portarias e extratos, incluindo o CNPJ verdadeiro da prefeitura citada. Nota-se também que o texto gerado reproduz artefatos de OCR presentes no corpus (acentuação perdida, letras trocadas por dígitos), o que é fidelidade ao material de treino e não degradação do modelo.

4.5. Benchmark de perguntas e respostas

Conforme sugerido no enunciado, foi construído um *benchmark* com 25 pares de pergunta e resposta de referência sobre o DOM-PI, em seis categorias (Entidades, Atos Administrativos, Territorial, Processos, Legislação e Dataset). As 25 perguntas foram respondidas com geração determinística pelos dois modelos, antes e depois do treino, e cada resposta foi classificada como acerto exato, acerto parcial ou erro frente à referência. A Tabela 5 resume a classificação.

Tabela 5. Classificação das 25 respostas do *benchmark* (Questão 01).

Modelo	Acertos exatos	Acertos parciais	Erros
Base (antes)	0	5	20
Treinado (depois)	6	7	12

O modelo base trata as perguntas como busca na web e não recupera nenhum fato exato. O modelo treinado, por sua vez, memorizou fatos pontuais do corpus: respondeu corretamente, caractere por caractere, o CNPJ da Prefeitura de Aroazes (06.554.984/0001-39), o CEP de Aroazes (64.310-000), o endereço da mesma prefeitura, o CNPJ da Prefeitura de Assunção do Piauí (01.612.561/0001-04) e o CEP da Prefeitura de Anísio de Abreu (64.780-000), além de citar a Lei 14.133/2021 na pergunta sobre legislação. A Figura 3 apresenta a visão por categoria sob um critério automático propositalmente estrito (a resposta de referência inteira deve estar contida na resposta gerada), no qual categorias conceituais, de resposta longa, zeram por construção; a leitura fina é a da classificação manual acima.




Figura 3. Benchmark por categoria sob o critério automático de contenção da referência. Os rótulos indicam acertos sobre o total de perguntas da categoria. O ganho concentra-se em Entidades, onde as referências são cadeias exatas como CNPJ e CEP.

4.6. Limitações e observações técnicas

Três pontos merecem registro. Primeiro, a memorização parcial cria *alucinações plausíveis*: na pergunta sobre o CNPJ da Câmara Municipal de Juazeiro do Piauí, o modelo treinado gera

um CNPJ bem formatado, porém errado, e ao ser perguntado sobre o número de territórios responde 18 em vez de 12. Esse comportamento é mais arriscado que a ignorância do modelo base, pois transmite falsa confiança. Segundo, o modelo é um modelo base, sem ajuste a instruções; nas perguntas conceituais ele tende a continuar o estilo de diário oficial em vez de responder, e por isso o *benchmark* deve ser lido como evidência qualitativa. Terceiro, a perplexidade final muito baixa (2,09) combina a adaptação real ao domínio com a natureza altamente padronizada e repetitiva do texto de diário oficial; como o conjunto de avaliação é *held-out*, não há vazamento, mas parte do mérito decorre da regularidade do corpus. Registre-se ainda que o aviso `missing keys: ['lm_head.weight']` ao carregar *checkpoints* é inofensivo, pois o Qwen2.5 compartilha os pesos da camada de saída com os *embeddings*.

5. Questão 02: Pós-Treino com SFT

5.1. Geração dos pares de instrução

O enunciado pede a geração de pelo menos 1.000 pares de instrução, entrada opcional e resposta a partir do docentesDC. Como não havia um modelo gerador disponível para sintetizar respostas, adotou-se uma restrição de projeto: toda resposta é derivada programaticamente do próprio dado e é verdadeira por construção, evitando ensinar alucinações como gabarito. O dataset bruto é ruidoso (código C, artigos em inglês fatiados, slides com formatação corrompida pelo OCR), o que exigiu um pipeline de preparação em quatro estágios: limpeza de artefatos e filtro de tamanho, classificação heurística de cada registro (português, inglês ou código), deduplicação por assinaturas de conteúdo e amostragem estratificada com teto de 200 registros por professor. A Figura 4 mostra o funil resultante: 13.762 registros brutos produziram 1.977 pares.




Figura 4. Funil do pipeline de preparação de dados da Questão 02. A deduplicação removeu cerca de 2.400 registros quase idênticos, típicos de artigos fatiados em blocos sobrepostos.

Antes da geração, 10% dos registros de cada professor foram reservados como *held-out*: os pares de avaliação provêm apenas desses registros, de modo que a métrica final não meça a memorização do próprio trecho visto em treino. Os pares seguem cinco tipos de tarefa, resumidos na Tabela 6 e na Figura 5, todos no molde de prompt do *Alpaca* [Taori et al. 2023].

Tabela 6. Tipos de pares gerados a partir do docentesDC.

Tipo	Tarefa	Resposta programática	Pares
A	Atribuição de origem	nome do professor dono do material	700
B	Continuação de trecho	continuação real do texto (só português)	500
C	Tema do trecho	tema inferido por vocabulário característico	377
D	Fatos sobre o dataset	fatos computados (19 docentes, volumes por professor)	200
E	Material com código	professor de origem e linguagem do código	200




Figura 5. Composição dos 1.977 pares por tipo de tarefa.

Os tipos A, B, C e E têm entrada preenchida com um trecho do material, de modo que a resposta é função determinística do contexto; o tipo D, sem entrada, injeta fatos que o modelo base certamente desconhece, permitindo uma demonstração qualitativa direta de aquisição de conhecimento. Após a formatação, exemplos cujo prompt não deixava espaço para a resposta dentro do limite de 256 tokens foram descartados, restando 1.728 pares de treino e 168 de avaliação.

5.2. Configuração do treino

O ajuste fino atualiza todos os 494 milhões de parâmetros. Aplicou-se a máscara de perda da Seção 2.5, de modo que apenas os tokens de resposta geram gradiente. A Tabela 7 resume a configuração.

Tabela 7. Configuração do SFT completo (Questão 02).

Item	Valor
Pares de treino / avaliação	1.728 / 168 (avaliação a partir de registros <i>held-out</i>)
Épocas	3, com seleção do melhor <i>checkpoint</i> por perda de validação
Tamanho de lote efetivo	16 (micro-lote 2, acumulação 8)
Taxa de aprendizado	5×10^{-5} com decaimento cosseno
Máscara de perda	prompt ignorado; perda apenas nos tokens de resposta
Tempo de treino / pico de VRAM	670 s (≈ 11 min) / 9,77 GB

5.3. Resultados quantitativos

A Tabela 8 e a Figura 6 apresentam as métricas sobre os tokens de resposta dos 168 pares de avaliação. A perplexidade caiu de 14,57 para 7,49 (redução de 48,6%) e a acurácia de tokens subiu 12,56 pontos percentuais.

Tabela 8. Métricas da Questão 02, calculadas apenas sobre os tokens de resposta.

Métrica	Antes	Depois	Variação
Entropia Cruzada	2,6793	2,0136	-24,8%
Perplexidade	14,57	7,49	-48,6%
Acurácia de Tokens	51,28%	63,84%	+12,56 p.p.




Figura 6. Métricas do SFT completo antes e depois do treino, sobre os tokens de resposta do conjunto de avaliação.

A Figura 7 revela um comportamento instrutivo: a perda de validação cai até a época 2 (0,914) e sobe na época 3 (0,992), enquanto a perda de treino despenca para cerca de 0,41. Com apenas 1.728 exemplos, o ajuste fino completo começa a decorar o conjunto de treino na terceira época. O mecanismo de seleção do melhor *checkpoint* restaurou automaticamente o modelo da época 2, e são dele as métricas reportadas.

5.4. Análise qualitativa

Dez perguntas fixas, com respostas de referência, foram respondidas por geração determinística antes e depois do treino. O modelo base errou as dez: divaga, mistura inglês ou responde com código Python irrelevante. O modelo ajustado obteve 6 acertos, 2 acertos parciais e 2 erros. Exemplos:

Pergunta: “*Quem é o professor com mais material no dataset docentesDC?*”

Antes: “O professor com mais material no dataset docentesDC é o professor que possui mais materiais, sendo ele o profê...” (circular).

Depois: “O professor com mais material no dataset docentesDC é Raimundo Santos Moura.” (correto)

Pergunta: “*Identifique o docente do DC/UFPI responsável por este trecho de material.*” (trecho *held-out* sobre arquitetura de computadores)




Figura 7. Curvas de perda do SFT completo. A perda de validação sobe na terceira época, caracterizando início de *overfitting*; o modelo final é o da época 2.

Antes: “The instruction is a load instruction that loads the value from memory address 0x00000000. . .” (responde em inglês, ignora a tarefa).

Depois: “Este material pertence ao professor Ivan Saraiva Silva.” (correto)

5.5. Limitações

Quatro limitações do processo de geração merecem registro. Primeiro, o rótulo de autoria significa “professor de cujo acervo o material provém”, e não autoria literal; há, por exemplo, slides de terceiros dentro do acervo de um docente. Segundo, o tema do tipo C é inferido por vocabulário no nível do documento, o que gera rótulos imprecisos para trechos específicos; um dos dois erros da avaliação qualitativa decorre desse ruído de gabarito. Terceiro, o tipo D repete um conjunto de cerca de 45 fatos únicos para compor os 200 pares, com os pares de avaliação construídos a partir de fatos disjuntos dos de treino. Por fim, como registros de um mesmo documento podem cair em treino e avaliação, o experimento mede generalização para trechos inéditos de documentos vistos, e não para documentos totalmente novos, o que é coerente com a tarefa de identificar a origem dos materiais.

6. Questão 03: Pós-Treino com QLoRA

6.1. Objetivo e configuração

A Questão 03 repete o pós-treino da Questão 02 substituindo o ajuste fino completo pela adaptação de baixo posto [Hu et al. 2022] sobre o modelo quantizado em 4 bits (QLoRA) [Dettmers et al. 2023]. Para uma comparação justa, foram reutilizados exatamente os mesmos pares, a mesma divisão treino/avaliação, a mesma máscara de perda e o mesmo tamanho de lote efetivo da Questão 02. A Tabela 9 resume a configuração do adaptador.

O plano original previa também a variante LoRA sem quantização, mas ela não pôde ser executada: a biblioteca PEFT instalada no ambiente Kaggle rejeitou a criação dos adaptadores sobre o modelo em fp32 por incompatibilidade com a versão antiga do pacote torchao pré-instalado na imagem. Trata-se de uma limitação de infraestrutura, registrada no log da execução; como o enunciado solicita LoRA e/ou QLoRA, a questão está atendida pela variante quantizada, cujo caminho de criação dos adaptadores não passa pelo componente defeituoso.

Tabela 9. Configuração do QLoRA (Questão 03).

Item	Valor
Quantização da base	4 bits NF4 com dupla quantização, cômputo em fp16
Posto r / fator α	16 / 32, <i>dropout</i> 0,05
Módulos adaptados	projeções de atenção (q, k, v, o)
Parâmetros treináveis	2.162.688 (0,44% do modelo)
Taxa de aprendizado	2×10^{-4} com decaimento cosseno
Épocas / lote efetivo	3 / 16, mesmos dados e divisão da Questão 02
Tempo de treino / pico de VRAM	1.079 s ($\approx$ 18 min) / 1,77 GB
Tamanho do adaptador salvo	8,7 MB

6.2. Efeito da quantização no modelo base

Avaliar o modelo base nas duas precisões, sobre o mesmo conjunto de avaliação, isola o custo da quantização: a perplexidade sobe de 14,57 (fp32) para 16,28 (4 bits), um acréscimo de 11,7%, e a acurácia de tokens cai 2,5 pontos percentuais (Figura 8). Esse é o preço de partida que o QLoRA paga para treinar com uma fração da memória.




Figura 8. Efeito da quantização NF4 sobre o modelo base, sem nenhum treino, no mesmo conjunto de avaliação da Questão 02.

6.3. Resultados quantitativos

Partindo do modelo quantizado (perplexidade 16,28), o QLoRA reduziu a perplexidade sobre os tokens de resposta para 6,40 (queda de 60,7%) e elevou a acurácia de tokens de 48,78% para 64,37%. A Figura 9 posiciona esses resultados ao lado dos da Questão 02, com os respectivos pontos de partida.

6.4. Comparação com o ajuste fino completo

O resultado central da questão está nas Figuras 10 e 11: o QLoRA atingiu perplexidade final *menor* que a do ajuste fino completo (6,40 contra 7,49) atualizando 228 vezes menos parâmetros, com pico de memória 5,5 vezes menor (1,77 GB contra 9,77 GB) e um artefato final de 8,7 MB contra cerca de 1 GB do modelo completo. Duas ressalvas contextualizam a comparação: as taxas de aprendizado diferem (valor usual de cada técnica) e o QLoRA




Figura 9. Métricas finais por técnica, com os dois baselines explicitados: o SFT completo parte da base em fp32 e o QLoRA parte da base quantizada em 4 bits. Métricas sobre os tokens de resposta do mesmo conjunto de avaliação.

parte de um baseline pior por causa da quantização, o que torna sua vantagem final ainda mais notável.

A explicação é visível nas curvas de validação: enquanto o SFT completo entrou em *overfitting* na terceira época (Seção 5), a perda de validação do QLoRA caiu monotonicamente (0,929; 0,881; 0,878). Com apenas 1.728 exemplos de treino, o adaptador de posto 16 age como uma regularização implícita: há menos graus de liberdade para decorar o conjunto de treino.




Figura 10. Parâmetros atualizados por técnica, em escala logarítmica. A razão entre o SFT completo e o QLoRA do mesmo modelo é de 228 vezes.

A avaliação qualitativa, porém, inverte o ranking e completa o quadro: nas mesmas dez perguntas da Questão 02, o QLoRA de 0,5 bilhão acertou apenas 2 (contra 6 do SFT completo), falhando principalmente nos fatos fechados sobre o dataset. A leitura conjunta é que atualizar todos os pesos memoriza conhecimento factual novo com mais força, enquanto o adaptador aprende bem o formato e a distribuição das respostas, mas retém menos fatos em um modelo desse porte. Afirmar superioridade do QLoRA apenas pela perplexidade seria, portanto, uma conclusão incompleta.

6.5. Experimento adicional: QLoRA no Qwen2.5-1.5B

Atendendo ao item opcional do enunciado, a mesma configuração de QLoRA foi aplicada ao Qwen2.5-1.5B. O modelo maior partiu de um baseline quantizado bem melhor (perplexidade 10,28, inferior até à base de 0,5 bilhão em fp32) e terminou com os melhores números do pós-treino: perplexidade 4,75, acurácia de tokens de 68,44% e 5 acertos




Figura 11. Custo e qualidade das três variantes de pós-treino executadas sobre os mesmos dados. O QLoRA domina o SFT completo em perplexidade e memória; o modelo de 1,5 bilhão quantizado obtém o melhor resultado geral.

qualitativos em 10, treinando 0,28% dos parâmetros em 2,75 GB de VRAM. Escala e adaptação eficiente se mostraram complementares: o 1,5B com QLoRA aproxima-se da qualidade factual do SFT completo gastando uma fração dos recursos.

7. Questão 04: Destilação de Conhecimento

7.1. Objetivo e configuração

A Questão 04 investiga a destilação de conhecimento entre dois modelos da família Qwen2.5: um professor Qwen2.5-3B-Instruct e um aluno Qwen2.5-1.5B-Instruct. A escolha de modelos da mesma família é deliberada, pois compartilham vocabulário e tokenizador, o que reduz incompatibilidades de distribuição. A técnica empregada é a destilação por *Chain-of-Thought* (Seção 2.7): o professor produz, para cada trecho, um raciocínio passo a passo e uma resposta final, e o aluno é ajustado sobre esses exemplos por meio de LoRA. A Tabela 10 resume a configuração.

7.2. Dataset sintético

O dataset de destilação foi gerado a partir de 100 trechos do corpus DOMPI-2025. Para cada trecho, o professor recebeu um *prompt* solicitando raciocínio explícito e resposta final em formato JSON, com os campos `instruction`, `input`, `output`, `reasoning` e `answer`. As instruções cobrem extração de informações típicas de diários oficiais, como CNPJ, CEP, endereços, valores de contrato, números de decreto e modalidades de licitação. O aluno foi então ajustado sobre esses pares, aprendendo tanto o formato das respostas quanto o padrão de raciocínio do professor.

Tabela 10. Configuração da destilação da Questão 04.

Item	Valor
Professor / Aluno	Qwen2.5-3B-Instruct (~6 GB) / Qwen2.5-1.5B-Instruct (~3 GB)
Técnica	Destilação por <i>Chain-of-Thought</i> + LoRA (SFTTrainer)
Dataset	DOMPI-2025, 100 trechos representativos (geração sintética)
Posto r / fator α	16 / 32, <i>dropout</i> 0,05
Módulos adaptados	q_proj, v_proj
Épocas / lote efetivo	3 / 16 (2×8 de acumulação de gradiente)
Taxa de aprendizado	2×10^{-4} , escalonador linear com <i>warmup</i>
Comprimento máximo / precisão	512 tokens / fp16
Ambiente	GPU NVIDIA RTX 4050 (6 GB)

7.3. Protocolo de avaliação

A qualidade foi medida por dois métodos complementares sobre um *benchmark* de 100 perguntas com respostas de referência. O primeiro é um critério automático de correspondência textual normalizada (*substring* e sobreposição de palavras $\geq 70\%$). O segundo é uma avaliação semântica por *LLM-as-Judge*, seguindo o protocolo de [Zheng et al. 2023], em que um LLM juiz classifica cada resposta como correta ou incorreta, tolerando diferenças de formatação, mas penalizando contradições e dados inventados. Além disso, as três métricas quantitativas usuais (entropia cruzada, perplexidade e acurácia de tokens) foram calculadas para o professor e para o aluno, antes e depois da destilação.

7.4. Resultados quantitativos

A Tabela 11 mostra que a destilação reduziu a perplexidade do aluno de 5,49 para 4,23 (queda de 22,9%) e a entropia cruzada em 15,2%, elevando a acurácia de tokens em 2,98 pontos percentuais. O aluno destilado chegou a *superar o professor* nas três métricas, resultado explicado pelo viés de ajuste: as métricas são calculadas sobre a mesma distribuição usada no treino do aluno, que se especializou no domínio, enquanto o professor permanece um modelo genérico.

Tabela 11. Métricas quantitativas antes e depois da destilação (Questão 04).

Modelo	Perplexidade	Entropia cruzada	Acurácia de tokens
Professor (3B)	4,50	1,5050	68,08%
Aluno antes (1.5B)	5,49	1,7022	65,65%
Aluno depois (1.5B)	4,23	1,4434	68,65%
Variação do aluno	-22,9%	-15,2%	+2,98 pp

7.5. Resultados qualitativos: dois métodos divergentes

O achado mais relevante da questão é a divergência entre os dois métodos de avaliação qualitativa (Tabela 12). Pela métrica automática de *substring*, o aluno melhorou de 36% para 42% de acertos (+6 pp), com 16 questões melhorando contra 10 regressões. Já pela

avaliação semântica por *LLM-as-Judge*, o aluno *piorou*, de 69% para 62% (-7 pp), com 17 regressões contra 10 melhoras; em 52 das 100 perguntas o julgamento não mudou (ambas corretas) e em 21 ambas seguiram incorretas.

Tabela 12. Acertos no *benchmark* de 100 perguntas por método de avaliação.

Método	Aluno antes	Aluno depois	Variação
<i>Substring</i> / sobreposição	36%	42%	+6 pp
<i>LLM-as-Judge</i> (semântico)	69%	62%	-7 pp

A explicação é que o ajuste por LoRA aproximou o *formato* das respostas do aluno ao do gabarito (favorecendo a correspondência textual), mas em vários casos introduziu alucinações, endereços e números de CNPJ/CEP inexistentes no documento, ou fez o modelo negar informações que antes acertava. A métrica de *substring* não penaliza esses erros quando o trecho correto também aparece; o juiz semântico, sim.

7.6. Houve transferência de conhecimento?

Sim, houve transferência, mas com evidências mistas quanto à sua qualidade. As três métricas quantitativas confirmam a transferência de forma inequívoca (perplexidade e entropia cruzada menores, acurácia maior), e o aluno chegou a superar o professor no domínio avaliado. Contudo, ao nível da corretude semântica das respostas, o aluno piorou. A lição central é que menor perplexidade não implica respostas mais confiáveis do ponto de vista factual: ganhos de formato e concisão podem mascarar perda de confiabilidade que só a avaliação semântica, ou humana, é capaz de capturar.

8. Questão 05: Geração Aumentada por Recuperação (RAG)

8.1. Objetivo e arquitetura

A Questão 05 constrói uma aplicação de RAG do tipo *Standard* (Seção 2.8) sobre o dataset docentesDC, com o objetivo de fornecer respostas ancoradas nos materiais acadêmicos reais dos docentes do Departamento de Computação, reduzindo as alucinações de um LLM genérico consultado sem contexto. O pipeline, implementado com a biblioteca LangChain, tem cinco etapas: carga e análise exploratória dos dados; consulta *baseline* ao LLM sem contexto (para evidenciar a alucinação); engenharia de RAG (fragmentação, *embeddings* e indexação); comparação prática; e avaliação por *benchmark*. A Tabela 13 resume os componentes.

8.2. Avaliação com Ragas

A qualidade foi medida sobre um *benchmark* (*golden dataset*) de 30 perguntas com respostas de referência, usando o *framework* Ragas [Es et al. 2024] com um LLM como juiz. A Figura 12 apresenta as três métricas: fidelidade 0,674, relevância da resposta 0,561 e precisão do contexto 0,430, todas abaixo do patamar ideal (0,85 para fidelidade).

8.3. Diagnóstico das pontuações

Uma análise linha a linha revelou que as notas baixas decorrem menos de falha do pipeline e mais de três fatores. Primeiro, há **desalinhamento entre o *benchmark* e o corpus**: várias

Tabela 13. Componentes do pipeline de RAG (Questão 05).

Item	Valor
Tipo de RAG	<i>Standard</i> (recuperação + geração)
LLM gerador	gpt-4o-mini
<i>Embeddings</i>	text-embedding-3-small (OpenAI)
Banco vetorial	ChromaDB persistente
Fragmentação	RecursiveCharacterTextSplitter, <i>chunk</i> de 1000 caracteres, <i>overlap</i> de 200
Filtragem	filtro por metadados (nome do docente) para elevar a precisão
<i>Prompt</i>	restritivo: responder apenas com base no contexto recuperado




Figura 12. Pontuações médias do Ragas no *benchmark* de 30 perguntas. A linha tracejada indica o patamar de referência de fidelidade (0,85).

perguntas assumem informações inexistentes no docentesDC (por exemplo, conceitos de compiladores atribuídos a um docente cujos 275 documentos tratam apenas de gestão de projetos). Quando a informação não existe, o *prompt* restritivo corretamente faz o modelo responder “não encontrei essa informação no contexto fornecido”, mas o Ragas atribui relevância e precisão zero a essa resposta honesta, derrubando as médias. Segundo, há uma **discrepância de metadados na avaliação**: o nome do docente é injetado no *prompt* durante a execução, mas apenas o texto cru é salvo para o Ragas, levando o juiz a interpretar como alucinação uma resposta que seguiu fielmente o contexto. Terceiro, ocorre **colisão semântica**: em perguntas gerais, planos de ensino (que contêm termos genéricos e o nome do docente) superam em similaridade os slides detalhados, que acabam omitidos do contexto.

8.4. Contribuição do RAG

Apesar das pontuações limitadas pelo desenho do *benchmark*, a contribuição do RAG é clara na comparação qualitativa. Sem recuperação, o modelo ou inventa conteúdo ou se recusa a responder de forma genérica; com RAG, ou cita o material real ou admite honestamente a ausência do dado no contexto. Por exemplo, à pergunta sobre os tópicos de um arquivo específico de um docente, o *baseline* respondeu com uma recusa genérica (“não tenho acesso a documentos específicos”), enquanto o RAG respondeu “não encontrei

essa informação no contexto fornecido”, comportamento factualmente correto e verificável. O trabalho aponta como próximos passos o alinhamento dos metadados enviados ao Ragas, o saneamento do *benchmark* e a adoção de recuperação hierárquica (*parent document retriever*).

9. Questão 06: Guardrails

9.1. Objetivo e arquitetura

A Questão 06 adiciona camadas de *guardrails* (Seção 2.9) sobre o Qwen2.5-0.5B pós-treinado por SFT na Questão 02, com o objetivo de quantificar o grau de proteção obtido. A arquitetura, inspirada no *NeMo Guardrails* [Rebedea et al. 2023], encadeia três trilhos executados em sequência, descritos na Tabela 14. Solicitações bloqueadas retornam um marcador [BLOQUEADO] e as fora de escopo, [REDIRECIONADO].

Tabela 14. Trilhos de *guardrails* implementados na Questão 06.

Trilho	Momento	Função
<i>Input rail</i>	antes do LLM	detecta, por <i>regex</i> , injeção de <i>prompt</i> e conteúdo perigoso
<i>Topic rail</i>	antes do LLM	restringe ao escopo do docentesDC; bloqueia perguntas curtas ou sem palavras do domínio
<i>Output rail</i>	após o LLM	filtra a resposta gerada e trunca respostas anormalmente longas

9.2. Protocolo de avaliação

A proteção foi medida sobre um *benchmark* de 30 perguntas, dividido em 20 solicitações legítimas sobre o domínio (ponteiros, algoritmos, sistemas operacionais, redes, bancos de dados) e 10 solicitações maliciosas ou fora de escopo que os trilhos deveriam bloquear (injeção de *prompt*, *jailbreak*, pedidos perigosos e perguntas alheias ao domínio). Coletaram-se a taxa de detecção de ameaças (TDR), a taxa de falsos positivos (FPR) e a disponibilidade para as solicitações legítimas.

9.3. Resultados

A Figura 13 resume os resultados. A camada de *guardrails* bloqueou **100% das ameaças** (10 de 10, nenhuma escapou) mantendo apenas **5% de falsos positivos** (1 de 20) e **95% de disponibilidade** para as solicitações legítimas. A matriz de confusão registra 10 verdadeiros positivos, 0 falsos negativos, 1 falso positivo e 19 verdadeiros negativos; entre os bloqueios, o *input rail* foi acionado 6 vezes e o *topic rail*, 5.

O único falso positivo foi uma pergunta legítima sobre proteção de domínios em sistemas Unix, rejeitada pelo *topic rail* por não conter palavras do vocabulário de domínio cadastrado, uma limitação da abordagem por lista de termos. Sem os *guardrails*, o modelo respondia indiscriminadamente a todas as solicitações, produzindo tanto conteúdo nocivo (instruções de invasão) quanto alucinações sobre assuntos fora do domínio. O grau de proteção adicionado é, portanto, substancial: a exposição a ameaças caiu a zero, com custo mínimo de disponibilidade. Como evolução natural, os autores apontam a migração dos trilhos por *regex* para uma solução completa como o *NeMo Guardrails*, com fluxos de diálogo e auditoria.




Figura 13. Guardrails da Questão 06: à esquerda, as métricas de proteção; à direita, a matriz de confusão sobre o *benchmark* de 30 perguntas.

10. Discussão

10.1. Visão consolidada

A Tabela 15 e a Figura 14 consolidam os quatro experimentos. Cada linha compara o modelo com o seu próprio ponto de partida; como a Questão 01 mede a sequência completa e as demais medem apenas os tokens de resposta, os valores absolutos não são comparáveis entre linhas, apenas as variações relativas.

Tabela 15. Resultados consolidados. PPL indica perplexidade e Acc a acurácia de previsão de tokens; cada experimento é comparado ao próprio baseline.

Experimento	PPL antes	PPL depois	Red. PPL	Acc antes	Acc depois	VRAM
Q1 Pré-treino (full-text)	21,78	2,09	90,4%	42,25%	82,03%	10,60 GB
Q2 SFT completo	14,57	7,49	48,6%	51,28%	63,84%	9,77 GB
Q3 QLoRA 0.5B	16,28	6,40	60,7%	48,78%	64,37%	1,77 GB
QLoRA 1.5B (adicional)	10,28	4,75	53,8%	55,82%	68,44%	2,75 GB

10.2. Pré-treino contra pós-treino

As questões ilustram dois regimes complementares de adaptação. O pré-treino continuado atua sobre a *competência linguística*: sem rótulos, apenas expondo o modelo ao corpus, reduziu a perplexidade em 90% e chegou a memorizar fatos pontuais do domínio, como CNPJs e CEPs de prefeituras. O pós-treino atua sobre o *comportamento*: com poucos milhares de exemplos, ensinou o modelo a responder no formato instrução/resposta e a devolver fatos do dataset docentesDC que o modelo base desconhecia por completo.

10.3. Eficiência contra memorização

A comparação entre as Questões 02 e 03 rendeu o achado mais interessante do trabalho. Pela métrica de perplexidade, o QLoRA venceu o ajuste fino completo (6,40 contra 7,49) com 0,44% dos parâmetros e 5,5 vezes menos memória; a explicação é a regularização




Figura 14. Antes e depois em cada experimento. A Questão 01 usa métrica de sequência completa e as demais usam métrica sobre tokens de resposta, portanto as escalas não são comparáveis entre experimentos.

implícita do adaptador de baixo posto, evidente nas curvas de validação (o SFT completo entrou em *overfitting* na terceira época, o QLoRA não). Pela avaliação qualitativa de fatos, a relação se inverte: 6 acertos do SFT completo contra 2 do QLoRA no modelo de 0,5 bilhão. Atualizar todos os pesos incorpora conhecimento factual novo com mais força; o adaptador aprende principalmente formato e distribuição. O experimento adicional sugere a saída prática para esse dilema: no modelo de 1,5 bilhão, o QLoRA recuperou a qualidade factual (5 acertos em 10) mantendo o custo baixo, indicando que, sob restrição de memória, vale mais adaptar eficientemente um modelo maior do que ajustar completamente um modelo menor.

10.4. Da adaptação à aplicação: destilação, RAG e guardrails

As Questões 04 a 06 deslocam o foco da adaptação de um modelo para o seu uso responsável, e reforçam, por caminhos independentes, o achado central das três primeiras. A destilação (Questão 04) é o espelho do dilema eficiência contra memorização: assim como o QLoRA venceu em perplexidade mas perdeu em fatos, o aluno destilado reduziu a perplexidade em 22,9% e ainda assim piorou na avaliação semântica, porque o ajuste aproximou o formato das respostas ao custo de introduzir alucinações. Essa é a mesma alucinação plausível observada na Questão 01, agora vista pela lente de um avaliador semântico: a divergência entre a métrica de *substring* e o *LLM-as-Judge* mostra que a escolha da métrica pode inverter a conclusão sobre se um modelo melhorou.

O RAG (Questão 05) responde diretamente a esse risco de alucinação: em vez de confiar na memória paramétrica do modelo, ancora a resposta em documentos recuperados, fazendo o sistema admitir a ausência de um dado em vez de inventá-lo. Já os *guardrails* (Questão 06) atacam a dimensão de segurança sobre o próprio modelo pós-treinado na Questão 02, bloqueando 100% das ameaças do *benchmark* com custo mínimo de disponibilidade. Em conjunto, as seis questões percorrem um arco coerente: adaptar o modelo ao domínio (Q1–Q3), comprimi-lo preservando o conhecimento (Q4), complementá-lo com recuperação externa (Q5) e protegê-lo no uso (Q6).

10.5. Limitações

Além das limitações específicas registradas nas Seções 4 e 5, cabem algumas observações gerais. Primeira, as métricas de perplexidade dependem da natureza do texto avaliado:

o valor 2,09 da Questão 01 reflete também a alta regularidade do texto de diário oficial. Segunda, a memorização factual induzida pelo treino produz alucinações plausíveis quando o fato pedido não foi retido, um risco maior que a ignorância explícita do modelo base. Terceira, a comparação entre SFT completo e QLoRA usa as taxas de aprendizado usuais de cada técnica e baselines de precisões diferentes, fatores que devem ser considerados na leitura dos números. Quarta, a variante LoRA sem quantização não pôde ser executada por incompatibilidade de bibliotecas no ambiente, de modo que a comparação de três técnicas de pós-treino ficou reduzida a duas.

Quanto às Questões 04 a 06, três ressalvas específicas merecem registro. Na destilação, o dataset sintético tem apenas 100 exemplos e as métricas quantitativas são calculadas sobre a distribuição de treino, o que favorece o aluno; conclusões robustas exigiriam um conjunto maior e uma avaliação fora da distribuição. No RAG, as pontuações do Ragas são deprimidas por lacunas do próprio *benchmark* e por uma discrepância de metadados na exportação da avaliação, de modo que os números subestimam a contribuição real da recuperação, evidente na análise qualitativa. Nos *guardrails*, os trilhos baseados em *regex* e em lista de termos são frágeis a variações não previstas, como mostra o único falso positivo, e uma solução de produção demandaria classificadores semânticos no lugar das regras manuais.

11. Considerações Finais

Este relatório documentou as seis questões do trabalho final sobre adaptação de modelos de linguagem ao domínio público piauiense, das técnicas de treinamento (pré-treino, SFT e QLoRA) às de compressão, recuperação e segurança (destilação, RAG e *guardrails*), sempre com avaliação estruturada antes e depois de cada intervenção.

A Questão 01 confirmou sua hipótese de forma robusta: o pré-treino continuado sobre 71.431 documentos do DOMPI-2025 reduziu a perplexidade de 21,78 para 2,09 e elevou a acurácia de previsão de tokens de 42,25% para 82,03%, sem *overfitting*. O *benchmark* de 25 perguntas, respondido pelos dois modelos, mostrou que o ganho vai além do estilo: o modelo treinado passou a acertar fatos exatos do corpus, como CNPIs e CEPs de prefeituras, saindo de zero acertos exatos para seis.

A Questão 02 demonstrou o ajuste fino supervisionado com um pipeline de dados inteiramente programático, que transformou 13.762 registros ruidosos do docentesDC em 1.977 pares de instrução verificáveis por construção. O treino reduziu a perplexidade sobre os tokens de resposta em 48,6% e fez o modelo responder corretamente fatos que antes desconhecia, com o episódio de *overfitting* na terceira época neutralizado pela seleção automática do melhor *checkpoint*.

A Questão 03 evidenciou o argumento central da adaptação eficiente: com 0,44% dos parâmetros e 1,77 GB de memória, o QLoRA superou a perplexidade do ajuste fino completo, ao custo de menor retenção factual no modelo de 0,5 bilhão. O experimento adicional com o Qwen2.5-1.5B quantizado obteve o melhor resultado geral do pós-treino (perplexidade 4,75), sugerindo que a combinação de escala com adaptação eficiente é o melhor uso de um orçamento fixo de memória.

A Questão 04 aplicou destilação por *Chain-of-Thought* de um professor Qwen2.5-3B para um aluno Qwen2.5-1.5B, confirmando a transferência de conhecimento nas métricas quantitativas (perplexidade 22,9% menor), mas revelando, pela

avaliação semântica com *LLM-as-Judge*, que menor perplexidade não implica respostas mais confiáveis, um alerta contra conclusões baseadas apenas em correspondência textual.

A Questão 05 construiu uma aplicação de RAG do tipo *Standard* sobre o docentesDC, avaliada pelo *framework* Ragas em 30 perguntas. Ainda que as pontuações absolutas tenham sido limitadas por lacunas do *benchmark* e por uma discrepância de metadados na avaliação, a comparação qualitativa demonstrou o valor da recuperação: com contexto, o sistema deixa de alucinar e passa a citar o material real ou a admitir honestamente a ausência do dado.

A Questão 06 adicionou uma camada de *guardrails* ao modelo pós-treinado na Questão 02 e mediu um grau de proteção elevado: 100% das ameaças bloqueadas com apenas 5% de falsos positivos e 95% de disponibilidade, endereçando na prática o dilema entre utilidade e segurança.

Como trabalhos futuros, pretende-se integrar as peças desenvolvidas em um único assistente para o domínio piauiense, combinando um modelo adaptado, recuperação de contexto e camada de proteção; ampliar o dataset de destilação e avaliá-lo fora da distribuição de treino; adotar recuperação hierárquica e saneamento do *benchmark* no RAG; e substituir os trilhos por *regex* dos *guardrails* por classificadores semânticos.

Referências

- [Dettmers et al. 2023] Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems (NeurIPS)*. Disponível em: <https://arxiv.org/abs/2305.14314>.
- [Es et al. 2024] Es, S., James, J., Espinosa-Anke, L., and Schockaert, S. (2024). RAGAs: Automated evaluation of retrieval augmented generation. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL): System Demonstrations*. Disponível em: <https://arxiv.org/abs/2309.15217>.
- [Gururangan et al. 2020] Gururangan, S., Marasovic, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D., and Smith, N. A. (2020). Don't stop pretraining: Adapt language models to domains and tasks. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 8342–8360. Disponível em: <https://arxiv.org/abs/2004.10964>.
- [Hinton et al. 2015] Hinton, G., Vinyals, O., and Dean, J. (2015). Distilling the knowledge in a neural network. *NeurIPS Deep Learning and Representation Learning Workshop*. Disponível em: <https://arxiv.org/abs/1503.02531>.
- [Hu et al. 2022] Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., and Chen, W. (2022). LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*. Disponível em: <https://arxiv.org/abs/2106.09685>.
- [Jelinek et al. 1977] Jelinek, F., Mercer, R. L., Bahl, L. R., and Baker, J. K. (1977). Perplexity—a measure of the difficulty of speech recognition tasks. *The Journal of the Acoustical Society of America*, 62(S1):S63.

- [Lewis et al. 2020] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*. Disponível em: <https://arxiv.org/abs/2005.11401>.
- [Mangrulkar et al. 2022] Mangrulkar, S., Gugger, S., Debut, L., Belkada, Y., Paul, S., and Bossan, B. (2022). PEFT: State-of-the-art parameter-efficient fine-tuning methods. Biblioteca de software. Disponível em: <https://github.com/huggingface/peft>.
- [Minari 2025] Minari, V. (2025). docentesDC: Materiais acadêmicos dos docentes do departamento de computação da UFPI. Conjunto de dados, Hugging Face Hub. Disponível em: <https://huggingface.co/datasets/vickminari/docentesDC>.
- [Ouyang et al. 2022] Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., et al. (2022). Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems (NeurIPS)*. Disponível em: <https://arxiv.org/abs/2203.02155>.
- [Portela 2025] Portela, G. (2025). DOMPI-2025: Diário oficial dos municípios do piauí. Conjunto de dados, Hugging Face Hub. Disponível em: <https://huggingface.co/datasets/gutoportelaa/DOMPI-2025>.
- [Qwen Team 2024] Qwen Team (2024). Qwen2.5: A Party of Foundation Models. Relatório técnico. Disponível em: <https://arxiv.org/abs/2412.15115>.
- [Rebedea et al. 2023] Rebedea, T., Dinu, R., Sreedhar, M., Parisien, C., and Cohen, J. (2023). NeMo Guardrails: A toolkit for controllable and safe LLM applications with programmable rails. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP): System Demonstrations*. Disponível em: <https://arxiv.org/abs/2310.10501>.
- [Taori et al. 2023] Taori, R., Gulrajani, I., Zhang, T., Dubois, Y., Li, X., Guestrin, C., Liang, P., and Hashimoto, T. B. (2023). Stanford Alpaca: An instruction-following LLaMA model. Repositório de código. Disponível em: https://github.com/tatsu-lab/stanford_alpaca.
- [Vaswani et al. 2017] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 30. Disponível em: <https://arxiv.org/abs/1706.03762>.
- [Wolf et al. 2020] Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., et al. (2020). Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP): System Demonstrations*, pages 38–45. Disponível em: <https://arxiv.org/abs/1910.03771>.
- [Zheng et al. 2023] Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., and Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems (NeurIPS)*. Disponível em: <https://arxiv.org/abs/2306.05685>.