

UNIVERSIDADE FEDERAL DO PIAUÍ (UFPI)
CENTRO DE CIÊNCIAS DA NATUREZA (CCN)
DEPARTAMENTO DE COMPUTAÇÃO (DC)

Disciplina: Tópicos em Inteligência Artificial
Professor: Raimundo Santos Moura – Período: 2026.1

**Pré-Treino e Pós-Treino de Modelos de Linguagem para o
Domínio Público Piauiense**

Relatório das Questões 01 (Pré-Treino Continuado), 02 (SFT) e 03
(LoRA/QLoRA)

Modelo base: Qwen2.5-0.5B (494M parâmetros)
Datasets: DOMPI-2025 (Diário Oficial dos Municípios do Piauí) e docentesDC (materiais dos docentes do DC/UFPI)
Ambiente de treino: Kaggle (1 GPU NVIDIA T4, 16 GB)

Autores

Allycia | Heverton | Izaías | Oscar

Teresina – PI
2026

1. INTRODUÇÃO

Modelos de linguagem de grande porte (*Large Language Models*, LLMs) são pré-treinados sobre vastos corpora de texto de propósito geral. Embora isso lhes confira fluência ampla, o conhecimento adquirido tende a ser raso em domínios especializados e em variedades regionais da língua, pouco representados nos dados de origem. Adaptar esses modelos a um domínio específico, com custo computacional acessível, é um problema central tanto na pesquisa quanto na aplicação prática de Processamento de Linguagem Natural ([GURURANGAN et al., 2020](#)).

Este relatório documenta três experimentos de adaptação do modelo Qwen2.5-0.5B ([Qwen Team, 2024](#)) ao domínio público piauiense, conduzidos no âmbito da disciplina de Tópicos em Inteligência Artificial. Cada experimento corresponde a uma questão do trabalho e a uma técnica distinta de treinamento:

- **Questão 01 – Pré-Treino Continuado.** Adaptação não supervisionada do modelo ao corpus DOMPI-2025 (Diário Oficial dos Municípios do Piauí), avaliando a qualidade da modelagem de linguagem antes e depois do treino.
- **Questão 02 – Pós-Treino com SFT.** Ajuste fino supervisionado (*Supervised Fine-Tuning*) sobre pares de pergunta e resposta gerados a partir do dataset docentesDC, atualizando todos os parâmetros do modelo.
- **Questão 03 – Pós-Treino com LoRA/QLoRA.** Repetição do experimento anterior por meio de adaptação de baixo posto (*Low-Rank Adaptation*), que atualiza menos de 1% dos parâmetros, comparando custo e qualidade frente ao ajuste fino completo.

As três técnicas são avaliadas pelas mesmas métricas quantitativas de modelagem de linguagem: perplexidade, entropia cruzada e acurácia de previsão de tokens ([JELINEK et al., 1977](#)). A hipótese geral é que o treinamento, em todas as suas formas, reduz a incerteza do modelo sobre o texto do domínio e melhora sua capacidade de previsão.

1.1 Estado dos experimentos e escopo do relatório

A Questão 01 foi executada de ponta a ponta em uma GPU NVIDIA T4 (Kaggle), com resultados completos antes e depois do treino. As Questões 02 e 03 tiveram a geração dos dados, o carregamento dos modelos e a avaliação *baseline* (antes do treino) concluídos; o laço de treinamento, contudo, foi interrompido em uma tentativa de execução local por restrição de tempo de hardware. Por essa razão, este relatório apresenta para as Questões 02 e 03 a metodologia completa e os resultados *baseline* reais já coletados, deixando as métricas pós-treino sinalizadas como *em andamento*. Essa decisão preserva a honestidade dos números reportados: nenhuma métrica é estimada ou fabricada. A Seção 8 detalha o caminho de conclusão dessas duas questões.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 Modelos de linguagem e o objetivo de pré-treino

Um modelo de linguagem autorregressivo, baseado na arquitetura *Transformer* (VASWANI et al., 2017), estima a probabilidade do próximo token x_t dado o contexto anterior, $P(x_t | x_{<t})$. O treinamento minimiza a entropia cruzada média entre a distribuição prevista e o token observado:

$$\mathcal{L} = -\frac{1}{N} \sum_{t=1}^N \log P(x_t | x_{<t}), \quad (1)$$

onde N é o número de tokens. O Qwen2.5-0.5B adotado neste trabalho possui 494 milhões de parâmetros, 24 camadas, dimensão oculta de 896 e vocabulário de 151.936 tokens (Qwen Team, 2024).

2.2 Pré-treino continuado (*continued pretraining*)

O pré-treino continuado consiste em prosseguir o treino não supervisionado de um modelo já pré-treinado sobre um corpus de um domínio-alvo, usando o mesmo objetivo da Equação 1. A técnica adapta o modelo ao vocabulário, ao estilo e às regularidades estatísticas do domínio sem necessidade de rótulos, e é reconhecidamente eficaz para domínios especializados (GURURANGAN et al., 2020). É a abordagem da Questão 01.

2.3 Pós-treino: ajuste fino supervisionado (SFT)

O *Supervised Fine-Tuning* (SFT) treina o modelo sobre pares de instrução e resposta, ensinando-o a seguir comandos e a responder no formato desejado (OUYANG et al., 2022). Os exemplos seguem tipicamente um molde de prompt como o do *Stanford Alpaca* (TAORI et al., 2023), com campos de instrução, entrada opcional e resposta. No SFT clássico (Questão 02), todos os parâmetros do modelo são atualizados, o que oferece máxima capacidade de adaptação ao custo de elevada demanda de memória e tempo.

2.4 Adaptação eficiente: LoRA e QLoRA

A *Low-Rank Adaptation* (LoRA) (HU et al., 2022) congela os pesos originais W_0 e aprende apenas um par de matrizes de baixo posto A e B , de modo que a atualização efetiva seja $W_0 + BA$, com $\text{posto}(BA) = r \ll d$. Como apenas A e B são treinados, o número de parâmetros atualizados cai em ordens de grandeza, reduzindo memória e tempo sem alterar a arquitetura na inferência.

O QLoRA (DETTMERS et al., 2023) estende a ideia carregando o modelo base *quantizado* em 4 bits (formato NF4) e aplicando os adaptadores LoRA sobre essa representação comprimida (DETTMERS et al., 2022). Isso permite ajustar modelos em GPUs modestas.

Ambas as técnicas são disponibilizadas pela biblioteca PEFT ([MANGRULKAR et al., 2022](#)) e correspondem à Questão 03.

2.5 Métricas de avaliação

As três questões usam o mesmo conjunto de métricas, calculadas sobre um conjunto de avaliação reservado (*held-out*):

- **Entropia cruzada:** a perda média da Equação 1; quanto menor, melhor o ajuste do modelo ao texto.
- **Perplexidade:** o exponencial da entropia cruzada, $PPL = e^{\mathcal{L}}$ ([JELINEK et al., 1977](#)). Interpreta-se como o número médio de opções entre as quais o modelo hesita por token; uma perplexidade próxima de 1 indica previsão quase determinística.
- **Acurácia de previsão de tokens:** a fração de tokens em que o token de maior probabilidade (*argmax*) coincide com o token real.

3. METODOLOGIA GERAL

3.1 Conjuntos de dados

DOMPI-2025 (Questão 01). O corpus DOMPI-2025 ([PORTELA, 2025](#)) reúne publicações do Diário Oficial dos Municípios do Piauí (DOM-PI) referentes a 2025, distribuídas em 12 territórios de desenvolvimento do estado. O texto foi extraído dos PDFs originais com PaddleOCR, Docling e PyMuPDF, totalizando 77.337 documentos brutos. Trata-se de linguagem jurídico-administrativa: portarias, decretos, extratos de contrato, editais de licitação e relatórios fiscais.

docentesDC (Questões 02 e 03). O dataset docentesDC ([MINARI, 2025](#)) contém materiais acadêmicos (slides, notas de aula, fragmentos de código e artigos) de 19 professores do Departamento de Computação da UFPI, em 13.762 registros com os campos `text` e `nome_professor`. É a base do pós-treino, da qual foram gerados os pares de pergunta e resposta usados no SFT e no LoRA/QLoRA.

3.2 Modelo e ambiente computacional

Todos os experimentos partem do mesmo modelo base, Qwen2.5-0.5B, carregado via biblioteca *Transformers* ([WOLF et al., 2020](#)). O treino de referência foi executado em uma única GPU NVIDIA T4 (16 GB) na plataforma Kaggle. A escolha de uma única T4 (em vez das duas disponíveis) foi deliberada: com duas GPUs, o Trainer ativaria *DataParallel* e concentraria os *logits* do vocabulário de 151 mil tokens em uma só placa, estourando a memória. O modelo de 0,5 bilhão de parâmetros cabe folgadoamente em uma T4.

Por exigência do *GradScaler* usado no treino em precisão mista (fp16 com *autocast*), os pesos mestres foram mantidos em fp32; sem isso, a T4, que não possui suporte de hardware a bfloat16, falhava no treino. Empregou-se *gradient checkpointing* para reduzir o consumo de memória.

3.3 Protocolo de avaliação

Para cada questão, o modelo é avaliado *antes e depois* do treino sobre o mesmo conjunto reservado, usando as métricas da Seção 2.5 (perplexidade, entropia cruzada e acurácia de tokens). Complementa-se a avaliação quantitativa com inspeção qualitativa de gerações livres a partir de prompts fixos, contrastando o comportamento do modelo base e do modelo treinado. A Tabela 1 resume a configuração das três questões.

Tabela 1: Visão geral das três questões e do estado de execução.

Questão	Técnica	Dataset	Params. treinados	Estado
01	Pré-treino continuado	DOMPI-2025	100% (494M)	Concluída (antes/depois)
02	SFT (full)	docentesDC	100% (494M)	Baseline coletado; treino em andamento
03	LoRA/QLoRA	docentesDC	0,44% (2,16M)	Baseline coletado; treino em andamento

4. QUESTÃO 01 – PRÉ-TREINO CONTINUADO

4.1 Objetivo e configuração

A Questão 01 realiza o pré-treino continuado do Qwen2.5-0.5B sobre o corpus DOMPI-2025, avaliando se o modelo melhora sua capacidade de modelar a linguagem jurídico-administrativa do Piauí. Dos 77.337 documentos brutos, 72.431 passaram pelo filtro de tamanho (entre 200 e 50.000 caracteres); destes, 71.431 foram usados no treino e 1.000 reservados para avaliação *held-out*. A Tabela 2 apresenta os hiperparâmetros efetivos.

4.2 Resultados quantitativos

A Tabela 3 e a Figura 1 apresentam as métricas sobre os 1.000 documentos reservados, antes e depois do treino. A perplexidade caiu de 21,78 para 2,09 (redução de 90,4%), a entropia cruzada caiu 76% e a acurácia de previsão de tokens quase dobrou, de 42,25% para 82,00%.

4.3 Dinâmica do treino e ausência de *overfitting*

O melhor *checkpoint* selecionado pelo Trainer (via `load_best_model_at_end` por `eval_loss`) foi o do último passo, ao fim da época 2, e não o da época 1. Isso indica que a perda de validação continuou caindo até o fim do treino: não houve sinal de *overfitting*, pois

Tabela 2: Hiperparâmetros do pré-treino continuado (Questão 01).

Item	Valor
Documentos de treino / avaliação	71.431 / 1.000 (held-out)
Épocas	2
Tamanho de lote efetivo	32
Taxa de aprendizado	5×10^{-5} (<i>cosine, warmup 5%</i>) (LOSHCHILOV; HUTTER, 2017)
Comprimento máximo de sequência	256 tokens
Precisão	fp32 + <i>autocast</i> fp16, <i>gradient checkpointing</i>
Passos de treino / tempo	4.466 passos / 16.821 s ($\approx$ 4h40 em 1 GPU T4)
Loss final de treino	0,8945
Melhor <i>checkpoint</i>	passo 4.466 (fim da época 2)

Tabela 3: Métricas da Questão 01 sobre o conjunto held-out (1.000 documentos).

Métrica	Antes	Depois	Δ	Variação
Entropia Cruzada	3,0812	0,7390	-2,3422	-76%
Perplexidade	21,78	2,09	-19,69	-90,4%
Acurácia de Tokens	42,25%	82,00%	+39,75 p.p.	+94%

um modelo que tivesse decorado o conjunto de treino teria visto a perda de validação subir na segunda época, levando o Trainer a preferir o *checkpoint* anterior. A avaliação final, portanto, foi feita no ponto ótimo.

4.4 Análise qualitativa

Submetendo os mesmos prompts ao modelo base e ao modelo treinado, o contraste é nítido: o modelo treinado produz texto administrativo autêntico do Piauí, enquanto o base divaga em conteúdo genérico, muitas vezes de outros estados.

Prompt: “O Prefeito Municipal, no uso de suas atribuições legais,”

Base: divaga sobre um “sorteio para o prêmio do Imposto sobre receitas brutas (IRBR) 2018”, texto genérico e fora de domínio.

Treinado: “...e com fulcro na Lei n. 14.133/2021 e demais normas pertinentes, RESOLVE, após exame criterioso de documentação ... RATIFICAR o procedimento licitatório referente a DISPENSA...”

Prompt: “EXTRATO DE CONTRATO. Contratante: Prefeitura Municipal de”

Base: “São Carlos – SP ... eleição do candidato à presidência da Câmara” (alucinação fora de domínio).

Treinado: “São João do Arraial-PI. Objeto: Aquisição de material permanente para a Secretaria Municipal de Educação. Recursos: Orçamento Geral. Valor global: R\$ 124.036,54...”




Figura 1: Métricas de modelagem de linguagem antes e depois do pré-treino continuado. A perplexidade despenca de ≈ 22 para ≈ 2 , indicando que o modelo passou a prever o próximo token com quase nenhuma hesitação no domínio.

O modelo treinado acerta a lei vigente de licitações (14.133/2021), cita municípios reais do Piauí (São João do Arraial, Simões) e reproduz a estrutura de portarias e extratos, inclusive com valores monetários formatados.

4.5 Benchmark de perguntas e respostas

Conforme sugerido no enunciado, foi construído um *benchmark* com 25 pares de pergunta e resposta de referência sobre o DOM-PI, distribuídos em cinco categorias (Entidades, Atos Administrativos, Territorial, Processos, Legislação e Dataset). A Tabela 4 mostra exemplos. No *benchmark*, o modelo base trata as perguntas como busca na web (“Blog do Carlos”, “Portal de Notícias”) e não recupera CNPJ, CEP ou e-mail corretos.

Tabela 4: Exemplos do *benchmark* de 25 pares pergunta/resposta (Questão 01).

Cat.	Pergunta	Resposta de referência
Legislação	Qual lei federal regulamenta as licitações e contratos municipais atualmente?	Lei Federal n. 14.133/2021, que substituiu a Lei n. 8.666/1993
Territorial	Quantos territórios compõem o dataset DOMPI-2025?	12 territórios
Atos Adm.	O que é uma Ata de Registro de Preços?	Documento que formaliza preços registrados após licitação, permitindo compras futuras sem nova licitação
Dataset	Qual o volume total de documentos e o período coberto pelo DOMPI-2025?	77.337 documentos cobrindo publicações de 2025 do DOM-PI

Esse resultado é esperado e reforça uma distinção importante: o pré-treino ensina o modelo a *falar* o domínio (modelagem de linguagem), não a *decorar* fatos pontuais como CNPJ ou CEP, que são memorização factual. Por isso a métrica central da questão é a perplexidade, e não a acurácia factual do *benchmark*.

4.6 Observações técnicas

Registram-se dois pontos metodológicos. Primeiro, o aviso `missing keys: ['lm_head.weight']` é inofensivo: o Qwen2.5 usa `tie_word_embeddings`, de modo que a camada de saída compartilha pesos com a matriz de *embeddings* e é reconstruída no carregamento. Segundo, a perplexidade final muito baixa (2,09) combina a adaptação real ao domínio com a natureza altamente templada e repetitiva do texto de diário oficial, de baixa entropia intrínseca; como o conjunto de avaliação é *held-out*, não há vazamento, mas vale registrar que parte do mérito decorre da regularidade do corpus.

5. QUESTÃO 02 – PÓS-TREINO COM SFT

5.1 Objetivo

A Questão 02 aplica o ajuste fino supervisionado (SFT) ao Qwen2.5-0.5B, atualizando *todos* os 494 milhões de parâmetros sobre pares de instrução e resposta derivados do dataset docentesDC. O objetivo é avaliar se o SFT melhora a capacidade do modelo de responder no estilo instrução/resposta sobre o conteúdo acadêmico do Departamento de Computação.

5.2 Geração dos pares de instrução e resposta

A partir dos registros do docentesDC foram gerados **3.111 pares** no formato `instruction / input / output`, valor que supera com folga o mínimo de 1.000 exigido pelo enunciado. Cada par associa uma instrução referente ao material de um professor a um trecho de resposta extraído desse material. Os pares são então formatados no molde de prompt estilo Alpaca ([TAORI et al., 2023](#)), como ilustra a Listagem 1.

```
### Instrução:
Explique o que é tratado neste trecho do material do professor
Weslley Emmanuel Martins Lima.

### Resposta:
Ponteiros são tipos especiais de dados que armazenam endereços de
memória. Uma variável do tipo ponteiro deve ser declarada da forma:
tipo *nome_variavel; ...<|endoftext|>
```

Listing 1: Exemplo de par formatado para o SFT (estilo Alpaca).

Os 3.111 pares foram divididos em 2.800 para treino e 311 para avaliação. A Tabela 5 resume a configuração do experimento.

Tabela 5: Configuração do SFT (Questão 02).

Item	Valor
Pares gerados (docentesDC)	3.111 (mínimo exigido: 1.000)
Split treino / avaliação	2.800 / 311
Parâmetros treinados	494M (100%, <i>full fine-tuning</i>)
Épocas / passos	3 / 525
Formato de prompt	estilo Alpaca (### Instrução / ### Resposta)

5.3 Resultado *baseline* (antes do SFT)

A avaliação do modelo base sobre o conjunto de 311 exemplos, antes de qualquer treino, produziu os valores da Tabela 6. Esses números são reais e servem de ponto de partida para a comparação pós-treino.

Tabela 6: *Baseline* da Questão 02: modelo base sobre o conjunto docentesDC, antes do SFT.

Métrica	Antes (baseline)	Depois (SFT)
Entropia Cruzada	3,3151	<i>em andamento</i>
Perplexidade	27,53	<i>em andamento</i>
Acurácia de Tokens	41,37%	<i>em andamento</i>

Qualitativamente, antes do SFT o modelo responde de forma vaga e genérica. Para a pergunta “Quem é o professor responsável pela disciplina de Tópicos em IA?”, o modelo base devolve “*O professor responsável ... é [Professor X]*”, evidenciando ausência de conhecimento específico sobre o corpo docente.

5.4 Estado da execução e pontos de melhoria identificados

O laço de treinamento do SFT foi iniciado, mas **interrompido manualmente** durante a primeira época. A execução tentada em uma GPU local estimava de 7 a 9 horas para completar os 525 passos, inviável dentro da janela de hardware disponível; diferentemente da Questão 01, este treino ainda não foi reexecutado na T4 do Kaggle. Em consequência, as métricas pós-treino, a comparação final e o salvamento do modelo permanecem pendentes (sinalizados como *em andamento* na Tabela 6).

A análise dos artefatos já gerados também revelou três oportunidades de melhoria de qualidade, a serem aplicadas antes da execução definitiva:

1. **Qualidade dos pares.** Parte das respostas é composta por texto bruto (fragmentos de código, trechos em inglês), o que tende a ensinar o modelo a regurgitar conteúdo em vez de transferir conhecimento. Recomenda-se deduplicar, filtrar idioma e garantir respostas coerentes em português.

2. **Máscara de *loss*.** A perda deve ser calculada apenas sobre os tokens da resposta (mascarando a instrução com -100 até o marcador ### Resposta:), para o modelo aprender a responder e não a reproduzir a pergunta.
3. **Perguntas de avaliação reais.** Substituir os marcadores genéricos (“professor X/Y”) por nomes que de fato constam no dataset (p. ex. Raimundo Moura, Erico Leão, André Soares, Vinícius Machado), tornando a comparação antes/depois significativa.

O caminho de conclusão desta questão, junto com a Questão 03, é detalhado na Seção 8.

6. QUESTÃO 03 – PÓS-TREINO COM LORA/QLORA

6.1 Objetivo

A Questão 03 repete o pós-treino da Questão 02, mas substitui o ajuste fino completo por adaptação de baixo posto (LoRA) (HU et al., 2022) sobre o modelo carregado em 4 bits (QLoRA) (DETTMERS et al., 2023). A meta é verificar se uma técnica que atualiza uma fração mínima dos parâmetros alcança qualidade próxima à do SFT completo, com custo de memória e tempo muito menores. Reaproveitam-se os mesmos 3.111 pares e o mesmo split (2.800/311) da Questão 02.

6.2 Configuração do adaptador

Os adaptadores LoRA foram inseridos nas camadas de projeção do modelo, resultando em apenas **2.162.688 parâmetros treináveis** de um total de 496.195.456, ou seja, **0,44%** do modelo. A Figura 2 contrasta esse custo com o do ajuste fino completo da Questão 02: o LoRA atualiza cerca de 228 vezes menos parâmetros.




Figura 2: Parâmetros atualizados no treino. O *full fine-tuning* da Questão 02 ajusta os 494M de parâmetros; o LoRA/QLoRA da Questão 03 ajusta apenas 2,16M (0,44%), em escala logarítmica.

Tabela 7: Configuração do LoRA/QLoRA (Questão 03).

Item	Valor
Modo	QLoRA (modelo base quantizado em 4 bits, NF4)
Parâmetros treináveis	2.162.688 de 496.195.456 (0,44%)
Dados / split	3.111 pares; 2.800 treino / 311 avaliação
Épocas / passos	3 / 525

6.3 Resultado *baseline* (antes do LoRA/QLoRA)

A Tabela 8 traz a avaliação do modelo base, em 4 bits, sobre os 311 exemplos de avaliação, antes do treino dos adaptadores.

Tabela 8: *Baseline* da Questão 03: modelo base quantizado, antes do LoRA/QLoRA.

Métrica	Antes (baseline)	Depois (LoRA/QLoRA)
Entropia Cruzada	3,5413	<i>em andamento</i>
Perplexidade	34,51	<i>em andamento</i>
Acurácia de Tokens	38,42%	<i>em andamento</i>

Nota-se que o *baseline* desta questão (perplexidade 34,51) é pior que o da Questão 02 (27,53), apesar de o modelo e o conjunto serem os mesmos. A explicação mais provável é a **quantização em 4 bits**: o QLoRA mede o *baseline* sobre a versão comprimida do modelo, cujos pesos aproximados elevam a perplexidade antes de qualquer treino. É justamente essa perda inicial que os adaptadores LoRA devem recuperar ao longo do ajuste.

6.4 Estado da execução

Assim como na Questão 02, o treino do LoRA/QLoRA foi iniciado e **interrompido** antes de concluir as 3 épocas, faltando as métricas pós-treino, a comparação final e o salvamento dos adaptadores. Vale destacar, contudo, uma evidência prática favorável à técnica já visível nos artefatos: enquanto o SFT completo da Questão 02 estimava de 7 a 9 horas de treino na GPU local, o LoRA/QLoRA estimava cerca de **21 minutos** no mesmo hardware, uma redução drástica coerente com o fato de atualizar apenas 0,44% dos parâmetros. Esse contraste de custo é o argumento central da comparação entre as Questões 02 e 03.

6.5 Ponto de correção identificado

A análise do notebook identificou um ajuste necessário para o modo LoRA puro (sem quantização): com *gradient checkpointing* ativo e sem `prepare_model_for_kbit_training` (que só roda no caminho QLoRA), ocorre o erro “*element 0 of tensors does not require grad*”. A correção é chamar `model.enable_input_require_grads()` antes de `get_peft_model`,

ou desativar o *gradient checkpointing* nesse modo. No caminho QLoRA padrão, usado nos resultados acima, o problema não ocorre.

7. DISCUSSÃO

7.1 Pré-treino contra pós-treino

As três questões ilustram dois regimes complementares de adaptação. O pré-treino continuado (Questão 01) atua sobre a *competência linguística* do modelo: sem rótulos, apenas expondo-o ao corpus do domínio, reduziu a perplexidade em mais de 90% e tornou suas gerações estilística e factualmente coerentes com o texto administrativo do Piauí. Já o pós-treino (Questões 02 e 03) atua sobre o *comportamento* do modelo, ensinando-o a responder no formato instrução/resposta. São objetivos distintos, e os resultados da Questão 01 mostram que o ganho mais expressivo, em termos de modelagem de linguagem pura, vem da exposição massiva ao domínio.

7.2 SFT completo contra LoRA/QLoRA

A comparação entre as Questões 02 e 03 é, em essência, uma análise de custo-benefício. Os *baselines* já coletados e o número de parâmetros treináveis (Tabela 9) deixam o trade-off evidente: o LoRA/QLoRA atualiza 0,44% dos parâmetros e estimou treino cerca de 20 vezes mais rápido que o ajuste fino completo no mesmo hardware. A hipótese a ser confirmada na execução final é a relatada na literatura (HU et al., 2022; DETTMERS et al., 2023): que essa fração mínima de parâmetros recupera a maior parte do ganho de qualidade do SFT completo, viabilizando o ajuste em GPUs modestas.

Tabela 9: Comparativo das três questões (valores “depois” de Q2 e Q3 pendentes de execução).

Questão	Params. treinados	PPL antes	PPL depois	Acc. antes
01 – Pré-treino	494M (100%)	21,78	2,09	42,25%
02 – SFT (full)	494M (100%)	27,53	<i>em andamento</i>	41,37%
03 – LoRA/QLoRA	2,16M (0,44%)	34,51	<i>em andamento</i>	38,42%

Ressalva de comparabilidade. As perplexidades não são diretamente comparáveis entre questões: a Questão 01 avalia sobre o DOMPI-2025, enquanto as Questões 02 e 03 avaliam sobre o docentesDC; além disso, o *baseline* da Questão 03 é medido sobre o modelo quantizado em 4 bits. A comparação válida é sempre *antes contra depois dentro da mesma questão*.

7.3 Limitações

Cabe registrar as limitações do estudo. (i) As Questões 02 e 03 ainda não têm métricas pós-treino, de modo que suas conclusões de qualidade são, por ora, hipóteses fundamentadas

no *baseline* e na literatura, não em resultados finais. (ii) A baixa perplexidade da Questão 01 é parcialmente atribuível à natureza repetitiva do diário oficial, e não apenas à adaptação do modelo. (iii) Os pares de QA gerados para o pós-treino têm qualidade desigual, conforme discutido na Seção 5, o que pode limitar o ganho do SFT antes das melhorias propostas. (iv) Empregou-se um único modelo de 0,5 bilhão de parâmetros; o requisito opcional de comparar modelos de tamanhos diferentes (p. ex. um Qwen2.5-1.5B via QLoRA) não foi realizado.

8. CONSIDERAÇÕES FINAIS

Este relatório documentou três experimentos de adaptação do Qwen2.5-0.5B ao domínio público piauiense. A Questão 01, concluída integralmente, confirma sua hipótese de forma robusta: o pré-treino continuado sobre o DOMPI-2025 reduziu a perplexidade de 21,78 para 2,09 (queda de 90,4%) e elevou a acurácia de previsão de tokens de 42,25% para 82,00%, sem sinais de *overfitting* e com clara transformação qualitativa das gerações, que passaram de texto genérico para linguagem administrativa autêntica do Piauí.

As Questões 02 (SFT completo) e 03 (LoRA/QLoRA) tiveram a metodologia, a geração dos 3.111 pares de instrução/resposta e a avaliação *baseline* concluídas com números reais, mas o treinamento foi interrompido por restrição de tempo de hardware na tentativa local. Optou-se por reportar esse estado de forma transparente, sem estimar métricas pós-treino. Os dados já evidenciam o principal trade-off entre as duas técnicas: o LoRA/QLoRA atualiza apenas 0,44% dos parâmetros e estimou treino cerca de 20 vezes mais rápido que o ajuste fino completo.

8.1 Caminho para conclusão das Questões 02 e 03

Para fechar as duas questões pendentes, basta reexecutar os notebooks na GPU T4 do Kaggle (o mesmo ambiente que viabilizou a Questão 01 em $\approx 4h40$), aplicando os ajustes já identificados:

1. aplicar as três melhorias de qualidade dos pares de QA da Seção 5 (deduplicação, filtro de idioma, máscara de *loss*) e as perguntas de avaliação com nomes reais de professores;
2. aplicar a correção do modo LoRA puro da Seção 6 (`enable_input_require_grads`);
3. executar o treino, coletar as métricas pós-treino e preencher as células “depois” das Tabelas 6, 8 e 9.

Como o conjunto docentesDC é muito menor que o DOMPI-2025, estima-se que cada treino leve apenas dezenas de minutos na T4, dominado pelo custo fixo de carregamento e avaliação. A estrutura deste relatório já está preparada para receber esses números.

8.2 Trabalhos futuros

O trabalho da disciplina prevê ainda três frentes não cobertas por este relatório, que dão sequência natural ao que foi construído: **(4)** destilação de conhecimento de um modelo professor para um aluno; **(5)** uma aplicação de RAG (*Retrieval-Augmented Generation*) sobre o DOMPI-2025 ou o docentesDC, capaz de recuperar fatos pontuais (CNPJ, CEP, e-mail) que o pré-treino não memoriza; e **(6)** a inclusão de camadas de *guardrails* sobre um dos modelos desenvolvidos. A frente de RAG, em particular, complementa diretamente a limitação de memorização factual observada no *benchmark* da Questão 01.

REFERÊNCIAS

- DETTMERS, T. et al. LLM.int8(): 8-bit matrix multiplication for transformers at scale. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2022. Disponível em: <https://arxiv.org/abs/2208.07339>.
- DETTMERS, T. et al. QLoRA: Efficient finetuning of quantized LLMs. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2023. Disponível em: <https://arxiv.org/abs/2305.14314>.
- GURURANGAN, S. et al. Don't stop pretraining: Adapt language models to domains and tasks. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S.l.: s.n.], 2020. p. 8342–8360. Disponível em: <https://arxiv.org/abs/2004.10964>.
- HU, E. J. et al. LoRA: Low-rank adaptation of large language models. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2022. Disponível em: <https://arxiv.org/abs/2106.09685>.
- JELINEK, F. et al. Perplexity—a measure of the difficulty of speech recognition tasks. *The Journal of the Acoustical Society of America*, v. 62, n. S1, p. S63, 1977.
- LOSHCHILOV, I.; HUTTER, F. *SGDR: Stochastic Gradient Descent with Warm Restarts*. 2017. International Conference on Learning Representations (ICLR). Disponível em: <https://arxiv.org/abs/1608.03983>.
- MANGRULKAR, S. et al. *PEFT: State-of-the-art Parameter-Efficient Fine-Tuning Methods*. 2022. Biblioteca de software. Disponível em: <https://github.com/huggingface/peft>.
- MINARI, V. *docentesDC: Materiais Acadêmicos dos Docentes do Departamento de Computação da UFPI*. 2025. Conjunto de dados, Hugging Face Hub. Disponível em: <https://huggingface.co/datasets/vickminari/docentesDC>.
- OUYANG, L. et al. Training language models to follow instructions with human feedback. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2022. Disponível em: <https://arxiv.org/abs/2203.02155>.
- PORTELA, G. *DOMPI-2025: Diário Oficial dos Municípios do Piauí*. 2025. Conjunto de dados, Hugging Face Hub. Disponível em: <https://huggingface.co/datasets/gutoportelaa/DOMPI-2025>.

Qwen Team. *Qwen2.5: A Party of Foundation Models*. 2024. Relatório técnico. Disponível em: <https://arxiv.org/abs/2412.15115>.

TAORI, R. et al. *Stanford Alpaca: An Instruction-following LLaMA Model*. 2023. Repositório de código. Disponível em: https://github.com/tatsu-lab/stanford_alpaca.

VASWANI, A. et al. Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, v. 30, 2017. Disponível em: <https://arxiv.org/abs/1706.03762>.

WOLF, T. et al. Transformers: State-of-the-art natural language processing. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP): System Demonstrations*. [S.l.: s.n.], 2020. p. 38–45. Disponível em: <https://arxiv.org/abs/1910.03771>.