

Adaptação de Modelos de Linguagem para o Domínio Público Piauiense

Questões 01 a 06 • Tópicos em Inteligência Artificial • 2026.1

Allycia Heverton Izaías Oscar

Departamento de Computação, UFPI
Professor: Raimundo Santos Moura

O trabalho em uma página

Seis questões sobre adaptar e usar com segurança modelos de linguagem no domínio do Piauí. O núcleo (Q1–Q3) adapta o **Qwen2.5-0.5B** com três técnicas, medindo tudo **antes** e **depois**:

- **Q1, Pré-treino continuado:** 71.431 diários oficiais do DOMPI-2025, sem rótulos
- **Q2, SFT completo:** 1.977 pares de instrução gerados do docentesDC, todos os pesos
- **Q3, QLoRA:** mesmos dados da Q2, modelo em 4 bits, só 0,44% dos parâmetros

Experimento	Dataset	Params. treinados	Tempo	VRAM
Q1 Pré-treino	DOMPI-2025	494M (100%)	4h23	10,60 GB
Q2 SFT completo	docentesDC	494M (100%)	11 min	9,77 GB
Q3 QLoRA	docentesDC	2,16M (0,44%)	18 min	1,77 GB
Extra: QLoRA 1.5B	docentesDC	4,36M (0,28%)	26 min	2,75 GB

Q1–Q3 em **uma única sessão de GPU T4 (Kaggle), 5h34**. As Questões **04** (destilação), **05** (RAG) e **06** (guardrails) estendem o estudo, com modelos, ferramentas e ambientes próprios.

Dados

- DOMPI-2025: 77.337 documentos OCR do Diário Oficial dos Municípios do PI
- docentesDC: 13.762 registros de 19 professores do DC/UFPI (slides, artigos, código)

Protocolo

- Mesmas métricas: perplexidade, entropia cruzada, acurácia de tokens
- Avaliação em conjunto reservado, geração determinística
- Q2/Q3: perda e métricas só nos **tokens de resposta** (máscara no prompt)


Cuidado de leitura

Q1 mede a sequência completa; Q2 e Q3 medem só a resposta. Escalas não são comparáveis entre questões, apenas as variações relativas.

Questão 01: Pré-Treino

Continuado

Q1: o modelo aprendeu o domínio




- Perplexidade: 21,78 para 2,09 (queda de 90,4%)
- Acurácia de tokens: 42,25% para 82,03%
- Perda de validação caindo até o fim (0,842 na época 1; 0,736 na época 2): sem overfitting

Q1: benchmark de 25 perguntas, antes e depois

	Exato	Parcial	Erro
Base	0	5	20
Treinado	6	7	12

- Acertos exatos, caractere por caractere: CNPJ e CEP de Aroazes, CNPJ de Assunção do Piauí, CEP de Anísio de Abreu
- Risco novo: **alucinação plausível** (CNPJ bem formatado, porém errado)



Q1: o mesmo prompt, dois modelos

“EXTRATO DE CONTRATO. Contratante: Prefeitura Municipal de”

Base (antes)

“São Pedro, do Distrito Federal, e do Município de Ipiranga... O Tribunal Regional Federal da 4ª Região...”

alucina, fora do domínio

Treinado (depois)

“São João do Arraial-PI, CNPJ n. 01.612.609/0001-84. Contratado: A. C. GOMES COMÉRCIO DE MATERIAIS ESPORTIVOS E CONSTRUÇÃO LTDA...”


município real, CNPJ verdadeiro

O modelo treinado cita a Lei 14.133/2021, municípios reais do Piauí e reproduz a estrutura de portarias e extratos.

Questão 02: Pós-Treino com SFT

Q2: dados verificáveis por construção

Sem modelo gerador disponível, toda resposta é derivada programaticamente do próprio dado: nada de alucinação como gabarito.




Cinco tipos de tarefa

- A: atribuição de origem (700)
- B: continuação do trecho (500)
- C: tema do trecho (377)
- D: fatos sobre o dataset (200)
- E: material com código (200)

10% dos registros de cada professor reservados antes da geração: a avaliação usa só trechos nunca vistos.

Q2: resultados e um episódio de overfitting



- Perplexidade (resposta): **14,57** para **7,49** (queda de 48,6%)
- Acurácia de tokens: **51,28%** para **63,84%**
- Validação sobe na época 3 (0,914 para 0,992): com 1.728 exemplos, o modelo começa a decorar
- A seleção automática do melhor checkpoint restaurou a época 2

Q2: o modelo passou a saber o que não sabia

“Quem é o professor com mais material no dataset docentesDC?”

Base (antes)

“O professor com mais material no dataset docentesDC é o professor que possui mais materiais, sendo ele o profe...”

resposta circular

SFT (depois)


“O professor com mais material no dataset docentesDC é Raimundo Santos Moura.”

correto

Nas 10 perguntas de avaliação: base **0 acertos**; SFT **6 acertos, 2 parciais, 2 erros**, incluindo atribuir trechos inéditos ao professor correto.


Questão 03: Pós-Treino com QLoRA

Q3: adaptação com 0,44% dos parâmetros



- Base quantizada em 4 bits (NF4); adaptadores de posto 16 nas projeções de atenção
- Mesmos dados, split, máscara e lote da Q2: comparação justa
- Preço da quantização no baseline: perplexidade de 14,57 para 16,28 (+11,7%)
- Adaptador final: **8,7 MB** (contra ≈ 1 GB do modelo completo)

Q3: QLoRA contra SFT completo



- Perplexidade final **menor** que a do SFT completo (6,40 contra 7,49) partindo de baseline pior
- 228 vezes menos parâmetros treinados, 5,5 vezes menos VRAM
- Explicação: o adaptador de baixo posto regulariza; a validação do QLoRA caiu monotonicamente enquanto o SFT completo overfitou

O achado central: eficiência contra memorização

Pela perplexidade

- QLoRA 0.5B: 6,40
- SFT completo: 7,49

Pelos fatos (10 perguntas)

- SFT completo: 6 acertos
- QLoRA 0.5B: 2 acertos

Leitura


- Atualizar todos os pesos memoriza fatos novos com mais força
- O adaptador aprende formato e distribuição, mas retém menos fatos no 0.5B
- **Saída prática:** QLoRA no 1.5B recupera os fatos (5 de 10) com perplexidade 4,75 em 2,75 GB

Conclusão da comparação

Sob restrição de memória, vale mais adaptar eficientemente um modelo maior do que ajustar completamente um modelo menor.

Visão consolidada das Questões 01 a 03

Antes e depois em cada experimento, cada um contra o próprio baseline



Q1 mede a sequência completa; Q2, Q3 e 1.5B medem apenas os tokens de resposta. As escalas não são comparáveis entre experimentos.

Questão 04: Destilação de Conhecimento

Q4: destilação por Chain-of-Thought (3B → 1.5B)

- Professor **Qwen2.5-3B** gera raciocínio e resposta; aluno **Qwen2.5-1.5B** aprende por LoRA
- Dataset sintético do DOMPI-2025 (100 trechos)
- Avaliação: *benchmark* de 100 perguntas mais métricas quantitativas

	PPL	Acc. tokens
Professor 3B	4,50	68,08%
Aluno antes	5,49	65,65%
Aluno depois	4,23	68,65%

Perplexidade do aluno de 5,49 para 4,23 (queda de 22,9%); no domínio, o aluno até supera o professor.

Q4: dois avaliadores, conclusões opostas

Método	Antes	Depois
<i>Substring</i>	36%	42%
<i>LLM-as-Judge</i>	69%	62%


- Pela correspondência textual, o aluno **melhora** (+6 pp)
- Pelo juiz semântico, o aluno **piora** (−7 pp): o ajuste aproximou o formato, mas introduziu alucinações

Lição

Menor perplexidade não implica respostas mais confiáveis: a métrica escolhida pode inverter a conclusão sobre a destilação.

Questão 05: RAG

Q5: RAG sobre o docentesDC reduz alucinações




- **Standard RAG:** LangChain + ChromaDB + gpt-4o-mini
- Avaliação Ragas em 30 perguntas: fidelidade 0,67, relevância 0,56, precisão 0,43
- Notas baixas vêm de lacunas do *benchmark*, não do pipeline

Contribuição do RAG

Sem contexto, o modelo inventa ou recusa; com RAG, cita o material real ou admite honestamente “não encontrei essa informação no contexto”.

Questão 06: Guardrails

Q6: guardrails sobre o modelo da Questão 02



- Três trilhos sobre o **Qwen2.5-0.5B** SFT: entrada, tópico e saída
- *Benchmark* de 30 (20 legítimas + 10 ameaças)
- 100% das ameaças bloqueadas, 5% de falsos positivos, 95% de disponibilidade

Sem *guardrails*, o modelo respondia a tudo, inclusive instruções nocivas: a exposição a ameaças caiu a zero, com custo mínimo de disponibilidade.

Conclusões

Conclusões

- **Q1:** o pré-treino continuado adaptou o modelo ao domínio (perplexidade 90% menor) e memorizou fatos exatos do corpus, com o risco novo de alucinações plausíveis
- **Q2:** um pipeline de dados programático viabilizou SFT eficaz e honesto, com overfitting neutralizado pela seleção de checkpoint
- **Q3:** QLoRA entregou a melhor perplexidade a uma fração do custo, com trade-off na retenção factual
- **Q4:** a destilação transferiu conhecimento nas métricas, mas o juiz semântico expôs alucinações
- **Q5:** o RAG trocou alucinação por citação do material real ou recusa honesta
- **Q6:** os guardrails bloquearam 100% das ameaças com 5% de falsos positivos

Arco do trabalho

Adaptar (Q1–Q3), comprimir preservando conhecimento (Q4), complementar com recuperação (Q5) e proteger no uso (Q6).

Obrigado!

Perguntas?